ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Разработка архитектуры верифицируемой системы Retrieval-Augmented Generation для поддержки принятия решений оператора атомной электростанции

АННОТАЦИЯ

В работе рассматривается задача разработки системы поддержки принятия решений для оператора атомной электростанции на основе архитектуры Retrieval-Augmented Generation (RAG). Проведен анализ существующих подходов к информационному поиску, генеративным моделям и методам верификации. Предложена архитектура системы, включающая гибридный поиск, генерацию ответов с учетом источников и модуль верификации. Определены метрики оценки эффективности и надежности системы. Особое внимание уделено вопросам безопасности и применимости в критичных отраслях.

СОДЕРЖАНИЕ

Введение

1. Обзор существующих подходов
2. Анализ предметной области
3. Разработка архитектуры системы
4. Модели и алгоритмы
5. Метрики и оценка эффективности
6. Безопасность и ограничения

Заключение

Список литературы

ВВЕДЕНИЕ

Актуальность темы обусловлена ростом объемов регламентной и технической документации в атомной энергетике, а также необходимостью повышения эффективности и надежности принятия решений операторами.

Современные большие языковые модели демонстрируют высокую эффективность в обработке естественного языка, однако их применение в критичных системах ограничено из-за риска генерации недостоверной информации.

Архитектура Retrieval-Augmented Generation позволяет объединить генеративные модели с внешними источниками знаний, обеспечивая повышение точности и трассируемости ответов.

Цель работы — разработка архитектуры верифицируемой RAG-системы для поддержки оператора АЭС.

Задачи:

- провести анализ методов retrieval и генерации;
- исследовать особенности информационных потоков АЭС;
- разработать архитектуру системы;
- определить методы верификации;
- предложить метрики оценки.

Объект исследования — процессы обработки информации оператором АЭС.

Предмет исследования — архитектуры интеллектуальных систем поддержки принятия решений.

1. ОБЗОР СУЩЕСТВУЮЩИХ ПОДХОДОВ

1.1 Архитектура Retrieval-Augmented Generation

RAG представляет собой подход, при котором генеративная модель использует внешние источники данных, извлекаемые с помощью поисковых механизмов. Это позволяет снизить уровень галлюцинаций и повысить обоснованность ответов.

Основные этапы:

- извлечение релевантных документов;
- формирование контекста;
- генерация ответа.

1.2 Методы информационного поиска

1.2.1 Dense retrieval

Метод поиска, основанный на векторных представлениях текста, который позволяет находить семантически близкие документы, а не только точные совпадения слов.

Как работает

1. Embedding: каждый документ и запрос преобразуются в вектор с помощью моделей типа Sentence-BERT или OpenAI embeddings.

2. Similarity Search: поиск документов с минимальным расстоянием до запроса в векторном пространстве (косинусная близость, dot-product).

Преимущества

- Семантический поиск независимо от формулировки и синонимов.
- Устойчивость к шуму и вариациям текста.
- Масштабируемость на большие базы через ANN индексы.
- Возможность комбинирования с keyword search для повышения точности.

Недостатки:

- снижение точности при строгих формулировках;
- ограниченная интерпретируемость.

1.2.2 Sparse retrieval

Основан на лексическом совпадении (например, BM25).

Преимущества:

- высокая точность при работе с регламентами;
- предсказуемость результатов.

Недостатки:

- слабая семантическая обобщающая способность.

1.2.3 Гибридные методы

Комбинируют dense и sparse подходы, обеспечивая баланс между точностью и полнотой поиска.

1.3 Агентные системы

Агентные архитектуры предполагают использование LLM для планирования и выполнения задач. Однако в критичных системах их применение ограничено необходимостью строгого контроля и детерминированности.

1.4 Методы обеспечения верифицируемости

- привязка к источникам (citation grounding);
- пост-обработка ответов;
- проверка логической согласованности;
- использование шаблонов.

1.5 Выводы по главе

Для критичных систем требуется комбинация:

- гибридного поиска;
- генерации с ограничениями;
- обязательной верификации.

2. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

2.1 Особенности эксплуатации АЭС

Оператор принимает решения в условиях:

- высокой ответственности;
- строгих регламентов;
- ограниченного времени.

2.2 Информационные потоки

Выделяются:

- оперативные данные;
- регламентные документы;
- аварийные инструкции.

2.3 Типы документов

- процедуры эксплуатации;
- технические регламенты;
- инструкции;
- журналы событий.

Документы обладают:

- строгой структурой;
- взаимными ссылками;
- версионностью.

2.4 Типы пользовательских запросов

- информационные;
- процедурные;
- диагностические;
- аварийные.

2.5 Требования к системе

- высокая точность;
- объяснимость;
- трассируемость;
- надежность.

3. РАЗРАБОТКА АРХИТЕКТУРЫ СИСТЕМЫ

3.1 Общая структура системы

Система включает следующие модули:

- обработка документов;
- индексация;
- поиск;
- генерация;
- верификация;

- пользовательский интерфейс.

3.2 Обработка документов

Включает:

- парсинг;
- извлечение структуры;
- нормализацию;
- разбиение на фрагменты.

3.3 Индексация

Используются:

- векторные представления;
- лексический индекс.

3.4 Поисковый модуль

Реализует:

- гибридный поиск;
- объединение результатов;
- ранжирование.

3.5 Генеративный модуль

Формирует ответ на основе:

- извлеченного контекста;
- заданных шаблонов.

3.6 Модуль верификации

Выполняет:

- проверку структуры ответа;
- проверку соответствия источникам;
- обнаружение противоречий.

3.7 Пользовательский интерфейс

Обеспечивает:

- отображение источников;
- журналирование;
- поддержку аудита.

4. МОДЕЛИ И АЛГОРИТМЫ

4.1 Гибридный поиск

Комбинируются:

- BM25;
- векторный поиск.

4.2 Ранжирование

Используется модель перекрестного кодирования для уточнения релевантности.

4.3 Генерация ответов

Применяются шаблоны, ограничивающие:

- структуру ответа;
- использование информации вне контекста.

4.4 Верификация

Алгоритмы включают:

- проверку покрытия ответа источниками;
- контроль диапазонов значений;
- выявление противоречий.

4.5 Обработка ошибок

- возврат к поисковому режиму;
- уведомление пользователя;
- логирование.

5. МЕТРИКИ И ОЦЕНКА ЭФФЕКТИВНОСТИ

5.1 Метрики поиска

- Precision@K — доля релевантных элементов в топ-K результатов.

  $$\text{Precision@K} = \frac{1}{K}\sum_{i=1}^{K} \text{rel}(i)$$

  где:

  - \mathrm{rel}(i) = 1, если элемент на позиции i релевантен, иначе 0

Где используется:

- RAG — качество извлечённых документов
- Router — качество выбора агентов
- Tool selection — корректность инструментов

Почему важно:

- понижает шум → уменьшает галюцинации
- уменьшает количество лишних шагов → уменьшает задержку
- умкньшение токенов → снижение стоимости

Ограничение: не учитывает полноту → нужен Recall@K.;

- Recall@K — доля найденных релевантных элементов из всех возможных.

  $$\text{Recall@K} = \frac{\sum_{i=1}^{K} \text{rel}(i)}{|\mathscr{R}|}$$

где:

- \mathrm{rel}(i) \in \{0,1\} — релевантность элемента на позиции i
- \mathcal{R} — множество всех релевантных элементов

Где используется:

- RAG — не пропускаем важные документы
- Router — покрытие возможных корректных агентов
- Tool selection — полнота вариантов

Почему важно:

- снижает риск пропуска критической информации;
- повышает устойчивость цепочек
- повышает итоговый success rate

Ограничение: может быть высоким при большом шуме → нужен Precision@K.

5.2 Метрики генерации

- ROUGE — метрика сходства сгенерированного текста с эталоном по перекрытию n-грамм/последовательностей.

  ROUGE\text{-}N = \frac{\text{совпавшие n-граммы}}{\text{n-граммы в reference}}

  Виды:

- ROUGE-1 / 2 — слова / биграммы
- ROUGE-L — порядок (LCS)

Где полезен:

- Summarization — задача сжатия текста с сохранением ключевого смысла и структуры.
- Regression-тесты в AI-агентных системах — это проверка того, что новая версия модели или цепочки агентов не ухудшила работу по сравнению с предыдущей.

Ограничения:

- не понимает смысл
- не ловит галлюцинации

Вывод: использовать только вместе с semantic-оценкой (LLM judge / success rate);

- F1-score — гармоническое среднее Precision и Recall: баланс между точностью и полнотой;
- Точность цитирования (Citation Accuracy / Faithfulness) — метрика, оценивающая, насколько сгенерированный ответ правильно ссылается на реальные источники или факты.

5.3 Метрики надежности

- Уровень галлюцинаций (Hallucination Rate) — доля сгенерированных ответов или шагов цепочки, которые не соответствуют реальности или фактам.

- Доля неподтверждённых утверждений (Unverified Statement Rate) — процент утверждений в ответе, которые не подтверждаются достоверными источниками или фактами.

5.4 Операционные метрики

- Время ответа (Response Time / Latency) — промежуток между получением запроса системой и выдачей результата;

- Устойчивость системы (System Robustness / Resilience) — способность AI-агентной системы сохранять корректную работу при нагрузке, сбоях или ошибках компонентов.

6. БЕЗОПАСНОСТЬ И ОГРАНИЧЕНИЯ

6.1 Ограничения языковых моделей

- Недетерминированность (Non-determinism) — свойство AI-агентной системы выдавать разные результаты на одни и те же входные данные при повторных вызовах;

- Чувствительность к входным данным (Input Sensitivity / Robustness to Input Variation) — степень, с которой малые изменения во входном запросе влияют на результат системы.

6.2 Риски применения

- генерация некорректных инструкций;
- пропуск критических действий;
- противоречивые рекомендации.

6.3 Методы снижения рисков

- участие человека в принятии решений;
- ограничение генерации;
- обязательная верификация;
- использование доверенных источников.

ГЛАВА 7. ИСПОЛЬЗОВАНИЕ ЛОКАЛЬНЫХ ЯЗЫКОВЫХ МОДЕЛЕЙ В КРИТИЧНЫХ СИСТЕМАХ

7.1 Актуальность применения локальных моделей

В контексте критичных отраслей, таких как атомная энергетика, использование облачных языковых моделей сопряжено с рядом ограничений, включая риски утечки данных, зависимость от внешней инфраструктуры и невозможность полного контроля над обработкой информации.

Локальные языковые модели (on-premise LLM) позволяют устранить указанные ограничения за счет выполнения всех вычислений внутри защищенного контура организации.

Основные преимущества:

- контроль над данными;

- соответствие требованиям информационной безопасности;
- независимость от внешних сервисов;
- возможность адаптации модели под предметную область.

7.2 Требования к локальным моделям

При выборе и внедрении локальной модели необходимо учитывать следующие требования:

1. **Надежность**
    - стабильное поведение при различных типах запросов;
    - минимизация галлюцинаций.
2. **Детерминированность**
    - воспроизводимость результатов;
    - контроль параметров генерации.
3. **Производительность**
    - допустимая задержка ответа;
    - возможность масштабирования.
4. **Интегрируемость**
    - поддержка API;
    - совместимость с RAG-архитектурой.
5. **Аудируемость**

    Аудируемость (auditability) — это свойство системы обеспечивать полную трассируемость всех операций, связанных с обработкой данных и принятием решений, с возможностью последующего анализа, проверки и воспроизведения результатов.

    - возможность логирования;

    - трассируемость решений.

7.3 Архитектура использования локальных моделей

Интеграция локальной модели в систему осуществляется как часть RAG-конвейера.

Основные компоненты:

- inference-сервер (LLM runtime);
- сервис генерации;
- модуль управления prompt;
- модуль верификации.

Локальная модель используется исключительно как компонент генерации и не рассматривается как источник истины.

7.4 Выбор моделей и оптимизация

При выборе модели учитываются:

- размер модели;
- качество генерации;
- требования к вычислительным ресурсам.

Подходы к оптимизации:

1. **Квантование**
    - снижение потребления памяти;
    - ускорение inference.
2. **Distillation**

    - уменьшение модели при сохранении качества.
3. **Fine-tuning**
    - адаптация под доменную область.
4. **Instruction tuning**
    - улучшение следования инструкциям.

7.5 Управление качеством генерации

Для повышения качества генерации применяются следующие методы:

- ограничение длины ответа;
- использование шаблонов;
- снижение температуры генерации;
- обязательное указание источников.

Особое значение имеет использование структурированных ответов, позволяющих упростить последующую верификацию.

7.6 Верификация при использовании локальных моделей

Локальные модели не устраняют проблему недостоверных ответов, поэтому требуется дополнительный слой верификации.

Основные механизмы:

1. **Проверка соответствия источникам**
    - все утверждения должны быть подтверждены retrieved-контекстом.
2. **Контроль структуры ответа**
    - соответствие заданному шаблону.

3. **Выявление противоречий**
    - анализ логической согласованности.
4. **Ограничение домена знаний**
    - запрет генерации вне заданной области.

7.7 Ограничения и риски

Несмотря на преимущества, локальные модели имеют ряд ограничений:

- более низкое качество по сравнению с крупными облачными моделями;
- высокие требования к вычислительным ресурсам;
- необходимость поддержки инфраструктуры;
- сложность обновления моделей.

7.8 Архитектурные рекомендации

Для эффективного использования локальных моделей рекомендуется:

1. Использовать модель только в составе RAG-системы.
2. Разделять уровни:
    - retrieval;
    - generation;
    - verification.
3. Обеспечивать изоляцию модели от критичных систем управления.
4. Реализовывать полный audit trail.
5. Использовать гибридный подход:
    - локальная модель — основной режим;
    - внешняя модель — для некритичных задач (при наличии).

7.9 Выводы по главе

Локальные языковые модели являются ключевым элементом при построении систем поддержки принятия решений в критичных отраслях.

Их применение позволяет обеспечить:

- контроль над данными;
- соответствие требованиям безопасности;
- независимость от внешней инфраструктуры.

Однако для достижения необходимого уровня надежности требуется:

- использование RAG-архитектуры;
- внедрение многоуровневой верификации;
- строгий контроль генерации.

Таким образом, локальная модель должна рассматриваться не как автономный интеллектуальный компонент, а как часть строго контролируемой инженерной системы.

ЗАКЛЮЧЕНИЕ

В работе разработана архитектура верифицируемой системы RAG для поддержки оператора атомной электростанции.

Основные результаты:

- проведен анализ существующих подходов;

- исследована предметная область;
- предложена архитектура системы;
- разработаны методы верификации;
- определены метрики оценки.

Практическая значимость заключается в повышении надежности систем поддержки принятия решений в критичных отраслях.

Перспективы дальнейших исследований:

- интеграция с системами мониторинга;
- развитие методов формальной верификации;
- применение нейро-символьных подходов.

СПИСОК ЛИТЕРАТУРЫ

1. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.
2. Robertson S. BM25 and Beyond.
3. Vaswani A. Attention is All You Need.
4. Gao L. et al. Retrieval-Augmented Generation Survey.
5. Документы МАГАТЭ по эксплуатации атомных электростанций.
6. Исследования по надежности и безопасности LLM.