Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский ядерный университет «МИФИ»
Институт физико-технических интеллектуальных систем (ИФТИС)
Кафедра «Автоматика»

ОТЧЁТ ПО ЗАДАНИЮ НА ПРОИЗВОДСТВЕННУЮ ПРАКТИКУ

(7 семестр)

на тему: «Интерактивный ассистент для поддержки принятия решений операторами АЭС на основе формирования и верификации гипотез о состоянии системы»

по направлению подготовки «Системный анализ и управление»
профиль «Информационно-измерительные и управляющие системы киберфизических устройств и установок»

Выполнил(а): студент группы Б23-605
Шелманова Ева Олеговна
_____

Руководитель практики:
Толоконский Андрей Олегович,
к.т.н., доцент кафедры «Теплофизика»
_____

Оценка: _____

Москва 2026

ЗАДАНИЕ НА ПРОИЗВОДСТВЕННУЮ ПРАКТИКУ

[Место для копии утверждённого задания на производственную практику (7 семестр)]

Согласно требованиям к отчёту копия задания размещается на второй странице. Сюда вставляется скан или копия подписанного задания (1-я копия – студенту, для включения в отчёт).

РЕФЕРАТ

Отчёт 54 с., 2 рис., 25 табл., 24 источн., 3 прил.

АТОМНАЯ ЭЛЕКТРОСТАНЦИЯ, ПОДДЕРЖКА ОПЕРАТОРА, ДИАГНОСТИКА АВАРИЙНЫХ РЕЖИМОВ, ГИПОТЕЗА О СОСТОЯНИИ, НЕЗАВИСИМАЯ ВЕРИФИКАЦИЯ, ВРЕМЕННЫЕ РЯДЫ, NPPAD, ИНФОРМАЦИОННЫЙ БАРЬЕР, КАЛИБРОВКА УВЕРЕННОСТИ, ПРОВЕРКА НОВИЗНЫ, ДЕТЕРМИНИРОВАННЫЕ ПРАВИЛА, ЯЗЫКОВАЯ МОДЕЛЬ

Объектом работы является информационная поддержка оператора атомной электростанции при диагностике аварийных режимов. Предмет – интерактивный ассистент, который формирует гипотезы о состоянии энергоблока по ограниченному набору измерительных каналов, независимо проверяет их по полному набору каналов и выпускает ответ оператору только после детерминированной проверки правилами.

Цель работы – развить прототип ассистента, созданный на учебной практике 6-го семестра, до системы поддержки принятия решений на основе формирования и верификации гипотез, удовлетворяющей тринадцати техническим требованиям задания.

В ходе работы разработаны модель данных и воспроизводимый конвейер подготовки открытого набора временных рядов аварийных режимов NPPAD, семантическая модель диагностической информации и информационный барьер; генератор калиброванных гипотез по шести каналам критических функций безопасности; верификатор гипотез по 82 каналам на основе квантильных сигнатур с учётом ранней фазы события; проверки отклонения и новизны; подбор аналогов из базы исторических событий ETH Zurich; детерминированный верификатор ответа по схеме «утверждение – свидетельство – набор правил – решение политики». Диагностический контур интегрирован с агентом-аналитиком ассистента, трассировкой Langfuse и программным интерфейсом.

На отложенной тестовой выборке система ставит диагноз в 95,2 % моментов времени с точностью 99,9 %, не выдаёт ложных диагнозов на ситуациях вне обучаемого множества и на внешнем стресс-тесте с изменением мощности, блокирует все 1680 контрольных испорченных ответов и обрабатывает окно наблюдений за 26 мс. Результаты воспроизводятся при повторном прогоне и при сборке из чистого окружения.

Результаты могут использоваться как основа выпускной квалификационной работы и как прототип подсистемы интерпретации данных в системах поддержки оператора, работающей в режиме «только чтение».

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ.....7
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ.....9
ВВЕДЕНИЕ.....10
1 Анализ предметной области и постановка задачи.....13
1.1 Поддержка оператора АЭС и требования безопасности.....13
1.2 Исходный прототип.....14
1.3 Требования к верификации ответа.....15
1.4 Постановка задачи.....15
2 Исходные данные.....18
2.1 Набор данных NPPAD.....18
2.2 Аудит классов.....19
2.3 База исторических событий ETHZ.....20
2.4 Внешний стресс-тест.....20
3 Модель данных.....22
3.1 Реестр каналов.....22
3.2 Конвейер подготовки данных.....22
3.3 Окна наблюдений и память о событии.....23
3.4 Контракты данных.....24
3.5 Семантическая модель.....25
3.6 Информационный барьер.....26
4 Методы формирования и проверки гипотез.....27
4.1 Генератор гипотез.....27
4.2 Верификатор гипотез.....28
4.3 Проверка отклонения и новизны.....30
4.4 Итоговое правило выбора.....30
4.5 Подбор аналогов.....31
5 Верификация ответа и интеграция с ассистентом.....33
5.1 Верификатор ответа.....33

5.2 Режимы работы.....34
5.3 Диагностический ответ.....34
5.4 Справка по сценариям.....35
5.5 Трассировка и программный интерфейс.....35
6 Программная реализация.....37
6.1 Технологии и структура.....37
6.2 Воспроизводимость.....37
6.3 Тестирование.....38
7 Экспериментальная оценка.....39
7.1 Методика.....39
7.2 Генерация гипотез.....39
7.3 Проверка гипотез и итоговые исходы.....39
7.4 Ситуации вне обучаемого множества и проверка новизны.....41
7.5 Внешний стресс-тест.....41
7.6 Верификатор ответа.....42
7.7 Пояснения языковой модели.....42
7.8 Поиск аналогов.....43
7.9 Производительность и воспроизводимость.....44
7.10 Ограничения.....44
ЗАКЛЮЧЕНИЕ.....46
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....48
ПРИЛОЖЕНИЕ А.....51
ПРИЛОЖЕНИЕ Б.....52
ПРИЛОЖЕНИЕ В.....53

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчёте применяют следующие термины с соответствующими определениями.

Гипотеза о состоянии – утверждение вида «вероятна ситуация X» с числовой уверенностью от 0 до 1, сформированное по наблюдаемым данным без рекомендаций действий.

Генератор гипотез – компонент, формирующий набор наиболее вероятных гипотез по ограниченному набору разрешённых каналов.

Верификатор гипотез – компонент, независимо от генератора проверяющий каждую гипотезу по полному набору наблюдаемых каналов и формирующий свидетельства.

Свидетельство – результат сравнения значения канала в окне наблюдений с ожидаемым для гипотезы диапазоном, имеющий направление («за» или «против»), вес и ссылку на канал и окно.

Информационный барьер – совокупность мер, исключающих доступ генератора гипотез к скрытым каналам и к истинной метке сценария.

Канал-подсказка (label_proxy) – параметр симулятора, непосредственно описывающий неисправность (например, расход течи) и потому фактически содержащий ответ.

Окно наблюдений – отрезок временного ряда всех каналов длиной 12 точек (120 с).

Память о событии – исходное состояние до начала события и наблюдения первых 120 с после его начала, доступные на текущий момент.

Прогон – одна симуляция сценария с заданной тяжестью.

Проверка новизны – определение того, что наблюдаемое событие не похоже ни на один сценарий обучающего множества.

Калибровка уверенности – согласование заявленной уверенности модели с фактической долей её правильных ответов.

Утверждение (Claim) – единичное проверяемое высказывание в ответе оператору со ссылками на свидетельства.

Набор правил (RulePack) – версионируемый перечень детерминированных проверок ответа.

Решение политики (PolicyDecision) – результат проверки ответа: выпустить (ALLOW), выпустить с пометкой о необходимости оценки оператором (REQUIRE_HUMAN) или заблокировать (BLOCK).

Паспорт версий – перечень версий моделей, данных, конфигурации и зависимостей, при которых получен результат.

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчёте применяют следующие сокращения и обозначения (таблица 1).

Таблица 1 – Сокращения и обозначения

Сокращение	Расшифровка
АЗ	аварийная защита реактора
АЭС	атомная электростанция
ВКР	выпускная квалификационная работа
КД	компенсатор давления
ПГ	парогенератор
САОЗ	система аварийного охлаждения активной зоны
API	Application Programming Interface – программный интерфейс
BM25	Best Matching 25 – функция ранжирования текстового поиска
ECE	Expected Calibration Error – ожидаемая ошибка калибровки
ETHZ	Curated Nuclear Events Database ETH Zurich – база событий на ядерных объектах
LLM	Large Language Model – большая языковая модель
NLL	Negative Log-Likelihood – отрицательное логарифмическое правдоподобие
NPPAD	Nuclear Power Plant Accident Data – набор временных рядов аварийных режимов АЭС
PCTRAN	Personal Computer Transient Analyzer – симулятор переходных процессов АЭС
PWR	Pressurized Water Reactor – водо-водяной реактор под давлением
RAG	Retrieval-Augmented Generation – генерация ответа с опорой на найденные документы
top-k	k наиболее вероятных гипотез

ВВЕДЕНИЕ

Актуальность. Оператор энергоблока АЭС при отклонении от нормальной эксплуатации должен за ограниченное время по сотням измеряемых параметров понять, что происходит, и принять решение. Системы информационной поддержки сокращают эту нагрузку, но в безопасностно значимой области к ним предъявляются особые требования: они не должны управлять оборудованием, не должны навязывать решений, их выводы должны быть объяснимы и проверяемы, а уверенность – соответствовать фактической надёжности [1, 2]. Языковые модели, на которых строятся современные ассистенты, этим требованиям сами по себе не удовлетворяют: их ответы вероятностны, а самооценка уверенности ненадёжна.

На учебной практике 6-го семестра был разработан прототип интерактивного ассистента atomic для операторов АЭС [3]: система ответов на вопросы по базе знаний на основе подхода RAG [4] с маршрутизатором запросов и агентами поиска, выполнения кода и анализа. Анализ прототипа показал, что подсистема проверки ответов была описана концептуально, но не реализована как исполняемая система: в ней не было модели доверия к источникам, формальных правил и механизма принятия решения о выпуске ответа. Проверка ответа ещё одной языковой моделью относится к тому же классу риска, что и основная модель, и для АЭС проверкой не является. Анализ направлений развития системы [5] определил следующий шаг – «мягкую интерпретацию» состояния станции: формирование нескольких гипотез о ситуации с калиброванной уверенностью и ссылками на аналогичные исторические события, без предписания действий.

Цель работы – развить прототип ассистента до системы поддержки принятия решений оператора на основе формирования и независимой верификации гипотез о состоянии энергоблока, в которой ответ оператору выпускается только после детерминированной проверки правилами.

Задачи определены тринадцатью техническими требованиями задания на практику:

1) сохранить работоспособность базового ассистента;

2) загружать и нормализовать временные ряды NPPAD и структурированные данные;

3) построить единую семантическую модель диагностической информации;

4) формировать гипотезы по ограниченному набору разрешённых каналов;

5) исключить доступ генератора к скрытым данным и истинной метке;

6) независимо проверять гипотезы по полному набору каналов;

7) формировать подтверждающие и противоречащие свидетельства и ссылки на аналоги событий;

8) передавать гипотезы в конвейер ассистента;

9) детерминированно проверять итоговый ответ;

10) обеспечить трассируемость и аудит;

11) выполнить компонентное и сквозное тестирование;

12) провести оценку качества генерации и проверки гипотез (benchmark);

13) обеспечить воспроизводимость результатов.

Объект исследования – информационная поддержка оператора АЭС при диагностике аварийных режимов. **Предмет исследования** – методы формирования, независимой верификации и выпуска гипотез о состоянии энергоблока по данным телеметрии.

Методы исследования: анализ предметной области и требований безопасности, статистический анализ временных рядов, методы машинного обучения (градиентный бустинг, калибровка вероятностей), квантильные модели нормального поведения, текстовый поиск, формальные правила и модели доверия, программная реализация на Python, экспериментальная оценка на отложенной выборке.

Работа выполнялась по технической дорожной карте [6], которая делит её на этапы: A – модель данных; B – методы формирования и проверки гипотез; C – интеграция и эксперименты; D – отчёт и защита практики; E – доводка и заморозка; F – выпускная работа. На момент составления отчёта этапы A, B, C и E выполнены, система заморожена. Каждое действие фиксировалось в журнале работ, каждое проектное решение – в реестре решений с обоснованием и альтернативами (44 решения).

Практическая значимость. Разработанный диагностический контур работает в режиме «только чтение», выдаёт проверяемые свидетельства со ссылками на конкретные каналы и моменты времени, честно сообщает о незнакомых ситуациях и пропускает к оператору только ответы, прошедшие проверку правилами. Он может служить прототипом подсистемы интерпретации данных и основой выпускной квалификационной работы.

Отчёт состоит из введения, семи разделов, заключения, списка использованных источников и трёх приложений. В разделе 1 проанализированы предметная область и исходный прототип, поставлена задача. Раздел 2 описывает исходные данные, раздел 3 – модель данных, раздел 4 – методы формирования и проверки гипотез, раздел 5 – верификацию ответа и интеграцию с ассистентом, раздел 6 – программную реализацию, раздел 7 – экспериментальную оценку.

1 Анализ предметной области и постановка задачи

1.1 Поддержка оператора АЭС и требования безопасности

Основная задача оператора в аварийной ситуации – поддержание критических функций безопасности энергоблока: подкритичности реактора, охлаждения активной зоны, теплоотвода, целостности первого контура, целостности защитной оболочки и запаса теплоносителя [7]. Именно их состояние оператор оценивает в первую очередь, а аварийные процедуры строятся вокруг их восстановления.

Требования к системам поддержки оператора следуют из общих принципов безопасности АЭС [1]: решение принимает человек, система не должна снижать его ситуационную осведомлённость и не должна вызывать чрезмерного доверия к автоматике. Чрезмерное доверие (automation bias) проявляется в том, что оператор принимает вывод системы без проверки, особенно если система выглядит уверенной [2]. Поэтому для диагностической системы важны не только точность, но и калибровка уверенности, способность отказаться от вывода и объяснимость каждого вывода.

Анализ эволюции ассистента [5] описывает пять этапов развития от информационного слоя (ответы по документам) до управляемых операций и устанавливает инварианты, которые не нарушаются ни на одном этапе:

– система не управляет оборудованием;
– человек всегда находится в контуре принятия решений;
– никакие действия не исполняются автоматически;
– доступ к данным станции – только на чтение;
– объяснимость выводов обязательна.

В анализе опасностей выделены, в частности, опасность Н3 (неверная классификация ситуации) и опасность Н4 (сверхуверенность системы). Меры защиты – выдача нескольких гипотез вместо одной и калибровка уверенности. Настоящая работа покрывает этап 1 (контекстный поиск по документам, реализован в 6-м семестре), этап 2 (мягкая интерпретация – гипотезы о

ситуации с уверенностью) и пассивную часть этапа 3 (ссылки на аналогичные исторические события без предписания действий).

1.2 Исходный прототип

Прототип atomic, разработанный в 6-м семестре [3], включает:

– консольный интерфейс и программный интерфейс FastAPI (запрос к ассистенту, проверка работоспособности);
– оркестратор AtomicWorkflow, передающий запрос по цепочке агентов и сохраняющий диалог;
– маршрутизатор RouterAgent, относящий запрос с помощью языковой модели к одному из типов: поиск, выполнение кода, анализ, общий вопрос;
– агентов RetrieverAgent (ответ по найденным фрагментам базы знаний), CommandAgent (генерация и выполнение кода Python в изолированном процессе) и AnalystAgent (рассуждение) с общим контрактом BaseAgent;
– память диалога и базу знаний в PostgreSQL с расширением pgvector [8] либо в памяти процесса;
– локальные языковые модели и модели векторных представлений через Ollama [9];
– трассировку запросов в Langfuse [10], развёртывание через Docker Compose, управление зависимостями uv [11];
– тесты pytest в быстром режиме и в полном режиме с оценкой релевантности ответа языковой моделью-судьёй [12, 13].

Прототип содержал около 1700 строк кода на Python. Его анализ в начале практики выявил расхождения между отчётом и кодом: подсистема проверки ответов и запасной текстовый поиск BM25 были описаны, но не реализованы; агенты возвращали только текст без структурированных утверждений и ссылок; данных о состоянии станции (телеметрии) в системе не было; база

знаний состояла из четырёх небольших текстовых файлов об устройстве самой системы.

1.3 Требования к верификации ответа

Замечание к работе 6-го семестра сформулировало требования к проверке ответа: верификатор должен быть подсистемой с формальными артефактами, а не дополнительным запросом к языковой модели. В безопасностно значимых областях принято разделять, что утверждается, на чём это основано, каким правилом проверено и кем выпущено [14]. Этому соответствует предложенная схема:

- **утверждение** – проверяемая фраза ответа;
- **ссылка на свидетельство** – идентификатор артефакта, на который опирается утверждение (документ, фрагмент базы знаний, результат расчёта, показание прибора), и вид источника;
- **набор правил** – версионируемый перечень детерминированных проверок;
- **решение политики** – выпуск, блокировка или передача человеку с машинно-читаемыми причинами.

Окончательное решение о выпуске ответа принимает детерминированный механизм; языковая модель может лишь помогать структурировать ответ.

1.4 Постановка задачи

Требуется дополнить ассистент диагностическим контуром, который по окну наблюдений телеметрии:

- формирует несколько гипотез о сценарии с калиброванной уверенностью, используя только ограниченный набор разрешённых каналов (требования 4, 5);

– независимо проверяет каждую гипотезу по полному набору наблюдаемых каналов, формирует свидетельства «за» и «против» и подбирает аналогичные исторические события (требования 6, 7);
– определяет, есть ли отклонение от исходного состояния и похожа ли ситуация на известные сценарии;
– передаёт результат агенту-аналитику, который строит ответ со ссылками, проходящий детерминированную проверку (требования 8, 9);
– оставляет трассу, по которой восстанавливается путь от данных до решения (требование 10).

Базовый ассистент должен сохранить работоспособность (требование 1), а результаты – быть измеримыми и воспроизводимыми (требования 11–13). Все инварианты раздела 1.1 сохраняются.

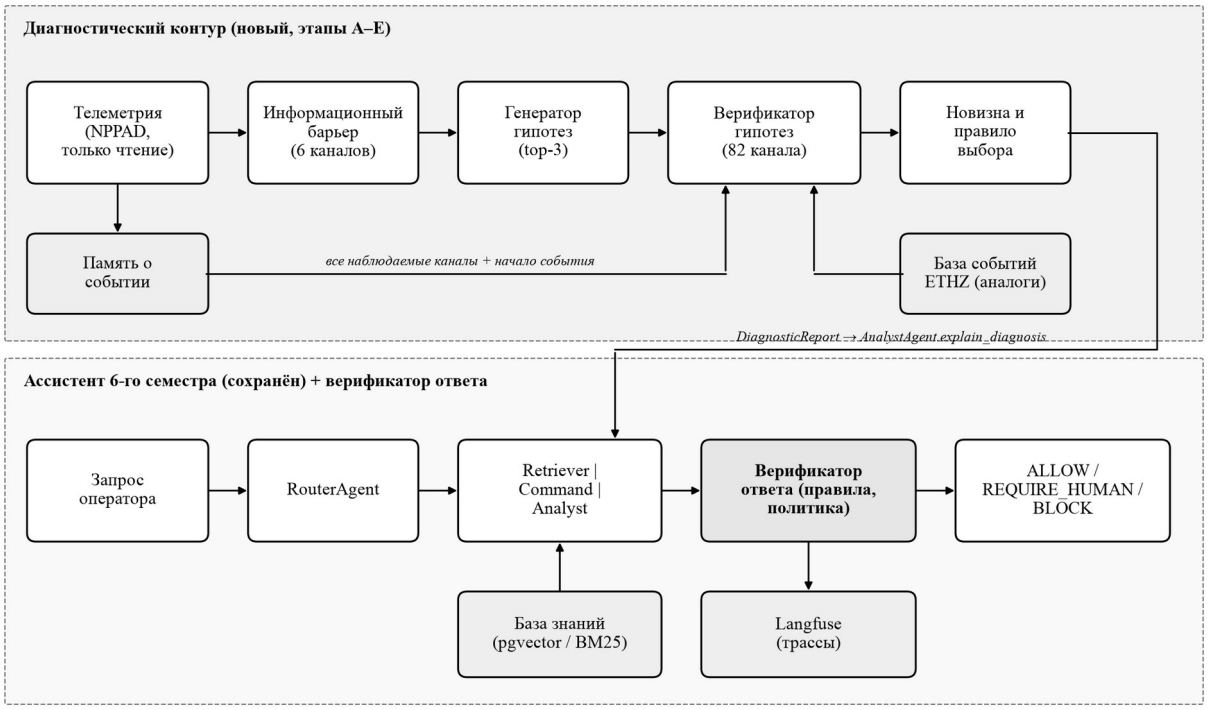


Рисунок 1 – Общая архитектура системы: диагностический контур и ассистент 6-го семестра

Архитектура (рисунок 1) состоит из двух контуров. Диагностический контур (новый) обрабатывает телеметрию; ассистент 6-го семестра

сохраняется без изменения цепочки агентов и дополняется верификатором ответа, через который проходят и обычные ответы, и диагностические.

2 Исходные данные

2.1 Набор данных NPPAD

Источник телеметрии – открытый набор временных рядов аварийных режимов АЭС NPPAD [15], полученный на симуляторе переходных процессов PCTRAN [16] для энергоблока с реактором PWR. Использована версия репозитория авторов от 25.08.2026 (коммит a8d54ed) в формате CSV (таблица 2).

Таблица 2 – Характеристики набора данных NPPAD

Характеристика	Значение
Исходное состояние	работа на 100 % мощности
Момент ввода неисправности	0,5 с от начала прогона
Шаг записи	10 с
Измерительных каналов	96
Классов ситуаций	18 (17 аварийных и нормальная эксплуатация)
Прогонов	1217
Точек времени	492 709
Лицензия	MIT

Сведения приведены в таблице 3.

Таблица 3 – Классы ситуаций NPPAD

Код	Ситуация	Прогонов
LOCA	течь теплоносителя первого контура, горячая нитка	100
LOCAC	течь теплоносителя первого контура, холодная нитка	100
SGATR, SGBTR	разрыв трубки парогенератора A, B	100, 110
SLBIC, SLBOC	разрыв паропровода внутри, вне защитной оболочки	101, 100
FLB	разрыв питательной линии	100
LLB	разрыв линии продувки во вспомогательном здании	101
LR	сброс нагрузки	99
RW, RI	извлечение, введение регулирующих стержней	100, 100
MD	разбавление борного раствора	100
ATWS	переходный процесс без срабатывания АЗ	1
LACP	потеря электропитания переменного тока	1
LOF	потеря расхода теплоносителя	1

Код	Ситуация	Прогонов
SP	горение водорода	1
TT	отключение турбины	1
Normal	нормальная эксплуатация	1

Номер файла прогона у классов с тяжестью означает тяжесть в процентах: для течей – процент от 100 см², для разрыва трубки парогенератора – процент от полного разрыва одной трубки, для стержней – процент извлечения или введения. Для каждого прогона симулятор формирует журнал событий (Transient Report) со временем срабатывания систем защиты.

При разборе данных обнаружены особенности, учтённые в загрузчике: три лишних столбца в 25 файлах SLBIC, отсутствующие в документации; порядок столбцов, отличный от документированного; семь каналов, постоянных на всей обучающей выборке; 18 прогонов RI короче 120 с; отрицательная запись тяжести у RI, из-за которой первоначально неверно определялась тяжесть (ошибка исправлена).

2.2 Аудит классов

Каждый прогон сравнён с прогоном, в котором неисправность введена с долей 0 % и станция остаётся в стационаре; мерой служило максимальное по времени и каналам отличие нормированных траекторий (таблица 4).

Таблица 4 – Результаты аудита классов NPPAD

Класс	Отличие от стационара, σ (медиана)	Вывод
MD	0,000	неисправность не проявилась ни в одном из 100 прогонов: концентрация бора постоянна (200 ppm)
SLBOC	0,000	теплогидравлика не меняется, отличаются только мониторы радиации паропровода и конденсатора
ATWS, SP	0,000	неисправность с долей 0 %, станция в стационаре
Normal	16,9	не стационар: закрывается клапан питательной воды
LLB	2,7	наименее выраженный из аварийных классов
LOCA, LOCAC	17,3; 17,1	выраженные изменения

По итогам аудита обучаемое множество составили 11 классов: FLB, LLB, LOCA, LOCAC, LR, RI, RW, SGATR, SGBTR, SLBIC, SLBOC. Прогоны MD, ATWS и SP служат эталоном «события нет», а однопрогонные LACP, LOF, Normal и TT – пробами ситуаций вне обучаемого множества. Однопрогонные классы нельзя использовать для обучения и честной оценки: разбиение одного прогона по времени поместило бы соседние окна и в обучение, и в проверку. Получить новые прогоны можно только симуляцией в PCTRAN; искусственное размножение данных не применялось.

2.3 База исторических событий ETHZ

Для подбора аналогов используется база ETH Zurich Curated Nuclear Events Database [17, 18] – 1561 событие на ядерных объектах с классификацией по типу исходного события, системе, компоненту и цепочке отказов. Распространяемый с базой файл ETHZ_Database_Access_tool.xlsm оказался интерфейсом на VBA: его листы пусты, а макрос выбирает строки из файла Support_file.xlsx по фильтрам и строит статистику. Логика выборки воспроизведена на Python без использования Excel. Оставлены 783 события на энергоблоках с реакторами PWR; у 352 из них размечен тип исходного события (Transient – 124, потеря внешнего электроснабжения – 108, потеря основной питательной воды – 33, разрыв трубки парогенератора – 29, малая течь – 23 и др.).

2.4 Внешний стресс-тест

Набор Variable_Power_Data из репозитория NPPAD содержит 12 прогонов: четыре нормальных изменения мощности в диапазоне 70–100 % и восемь аварий (LOCA, RW, SGATR, SGBTR) на фоне изменения мощности. Данные распространялись только в формате баз Access и прочитаны средствами Python. В обучение набор не входит. Поскольку все обучающие прогоны начинаются со 100 % мощности, стресс-тест проверяет поведение

системы в незнакомом режиме: правильным считается отсутствие ложных диагнозов.

3 Модель данных

3.1 Реестр каналов

Все 96 каналов описаны в реестре конфигурации: каноническое имя, описание, единица измерения, подсистема (первый контур – 19, второй контур – 15, радиационный контроль – 13, активная зона – 10, топливо – 7, защитная оболочка – 7, САОЗ – 6, тяжёлая авария – 6, КД – 5) и признак канала-подсказки. Восемь каналов-подсказок (расход и энергия течи, течь трубок ПГ, разрыв питательной линии) не измеряются штатными приборами и фактически содержат ответ; они исключены из генератора и верификатора. С учётом семи постоянных каналов верификатор использует 82 наблюдаемых канала.

Генератор видит шесть разрешённых каналов – по одному на каждую критическую функцию безопасности [7] (таблица 5).

Таблица 5 – Разрешённые каналы генератора гипотез

Критическая функция безопасности	Канал	Величина
подкритичность	PWNT	мощность по нейтронному потоку, %
охлаждение активной зоны	TAVG	средняя температура теплоносителя, °C
теплоотвод	PSGA	давление в ПГ A, бар
целостность первого контура	P	давление в первом контуре, бар
защитная оболочка	PRB	давление в здании реактора, бар
запас теплоносителя	LVPZ	уровень в КД, %

Набор задан в конфигурации и не подбирался под точность классификатора. Он намеренно неполон: по этим каналам, например, плохо различаются разрывы трубок ПГ A и B. Различение обеспечивает верификатор, видящий все наблюдаемые каналы.

3.2 Конвейер подготовки данных

Подготовка выполняется одной командой за 15 с и включает чтение и приведение столбцов к реестру, проверку сетки времени, присвоение

непрозрачных идентификаторов, раздельное хранение меток, разбиение и нормализацию, сохранение данных с манифестом версий.

Идентификаторы. Пути файлов содержат имя сценария, поэтому идентификатор прогона – 12 символов хэша SHA-256 от пути, идентификатор окна – 16 символов хэша от идентификатора прогона и номера точки. Исходный путь и метки (сценарий, тяжесть, номер неисправности) хранятся в отдельном хранилище, доступном только обучающим скриптам и оценщику.

Разбиение. Прогоны делятся на обучающую, валидационную и тестовую выборки в пропорции 60/20/20, стратифицированно по сценарию, с фиксированным начальным значением генератора случайных чисел. Разбиение по прогонам исключает попадание соседних окон одного прогона в разные выборки. Для 11 классов получено 667, 222 и 222 прогона. Валидационная выборка используется для выбора моделей и порогов, тестовая – только для итоговой оценки.

Нормализация. Каналы приводятся к z-оценкам; среднее и стандартное отклонение вычисляются только по обучающим прогонам.

Манифест содержит коммит источника, хэш конфигурации, порядок каналов, параметры нормализации и состав выборок. Хэш конфигурации данных вычисляется только по разделам, влияющим на данные, поэтому изменение порогов верификатора не делает данные устаревшими.

3.3 Окна наблюдений и память о событии

Прогон нарезается на окна длиной 12 точек (120 с) со сдвигом 6 точек (60 с); окна строятся детерминированно из сохранённых данных. Всего в наборе около 80 тыс. окон, в тестовой выборке 11 классов – 13 984.

Эксперимент показал, что по одному окну течи в горячей и холодной нитке различаются плохо: бинарный классификатор по 574 признакам окна достиг точности лишь 0,54. По окнам первых 300 с точность составила 0,885, а по изменениям каналов через 30, 60 и 120 с от начала события относительно исходного состояния 40 валидационных прогонов разделились без ошибок.

Результат сохранился при добавлении шума 5 % и при исключении восьми наиболее информативных каналов. Поэтому модель данных дополнена памятью о событии – исходным состоянием и наблюдениями первых 120 с после начала события. Память причинна: в неё входят только точки, уже наблюдавшиеся к концу текущего окна.

Начало события определяется по данным, без знания момента ввода неисправности. Точка стационарна, если ни один наблюдаемый канал не изменился больше чем на 1 % за предыдущие 60 с; начало события – последняя стационарная точка перед отклонением. Событие считается законченным, только когда станция 120 с подряд стационарна и вернулась к состоянию до события. Защёлка необходима потому, что после аварии станция выходит на новое, но ненормальное стационарное состояние; без неё событие преждевременно «закрывалось» бы в 25,6 % окон валидационной выборки, с ней – в 1,1 %. На всех тестовых прогонах NPPAD найденное начало совпадает с началом записи.

3.4 Контракты данных

Модули обмениваются типизированными контрактами с проверкой инвариантов и сериализацией (таблица 6).

Таблица 6 – Контракты диагностического контура

Тип	Содержание	Инварианты
ObservationWindow	окно по всем каналам	форма данных согласована со списком каналов
RestrictedWindow	окно по разрешённым каналам	создаётся только барьером; нет метки, времени и прогона
EpisodeContext	память о событии	только прошлые точки
ScenarioHypothesis	сценарий, уверенность, ранг	уверенность в [0; 1]; без рекомендаций действий
HypothesisSet	набор гипотез top-k	по убыванию уверенности; сумма не больше 1
ChannelEvidence	свидетельство с весом и направлением	ссылка вида <окно>#<канал>

Тип	Содержание	Инварианты
EventAnalogue	аналогичное историческое событие	формулировка «в аналогичных случаях наблюдалось…»
HypothesisVerdict	статус проверки гипотезы	подтверждена, отклонена или не определено
NoveltyAssessment	результаты проверок отклонения и новизны	расстояния и пороги
DiagnosticReport	итог диагностики окна	исход из конечного множества

Контракты верификатора ответа (Claim, EvidenceRef, Rule, RulePack, PolicyEffect, PolicyDecision, VerificationBundle) перенесены из проекта 7-го семестра без изменения смысла полей; к видам свидетельств добавлены телеметрия и историческое событие, к утверждению – необязательные атрибуты для правил.

3.5 Семантическая модель

Единая модель диагностической информации реализована как граф знаний с явной схемой допустимых связей. Узлы: канал, прогон, окно, сценарий, историческое событие, документ, фрагмент, гипотеза, свидетельство, утверждение, правило, пакет правил, решение политики. Связи: «часть» (окно – прогон, фрагмент – документ, правило – пакет), «наблюдает» (окно – канал), «о чём» и «предлагает» (гипотеза – окно, сценарий), «ссылается» (свидетельство – канал, окно, событие, фрагмент), «поддерживает» и «противоречит» (свидетельство – гипотеза или утверждение), «аналогично» (событие – сценарий), «проверено» (утверждение – правило), «решает» и «применяет» (решение – утверждение, пакет). Недопустимая связь вызывает ошибку; каждый узел хранит происхождение (источник, версию, время). Путь «данные → гипотеза → проверка → ответ → решение» восстанавливается в графе по цепочке «канал – окно – гипотеза – свидетельство – утверждение – решение – пакет правил». Графовая СУБД не используется: объём графа невелик, а проверяемая схема важнее масштабирования.

3.6 Информационный барьер

Требование 5 обеспечено на трёх уровнях. На уровне типа данных генератор принимает только RestrictedWindow, не содержащий метки, времени и идентификатора прогона. На уровне проекции барьер оставляет только разрешённые каналы конфигурации, а каналы-подсказки запрещены уже при её загрузке. На уровне идентификаторов и меток идентификаторы не содержат имени сценария, метки хранятся отдельно, а модули рабочего пути генератора не импортируют модуль меток, что проверяется статическим тестом. Все уровни покрыты контрактными тестами, в том числе на реальных данных.

4 Методы формирования и проверки гипотез

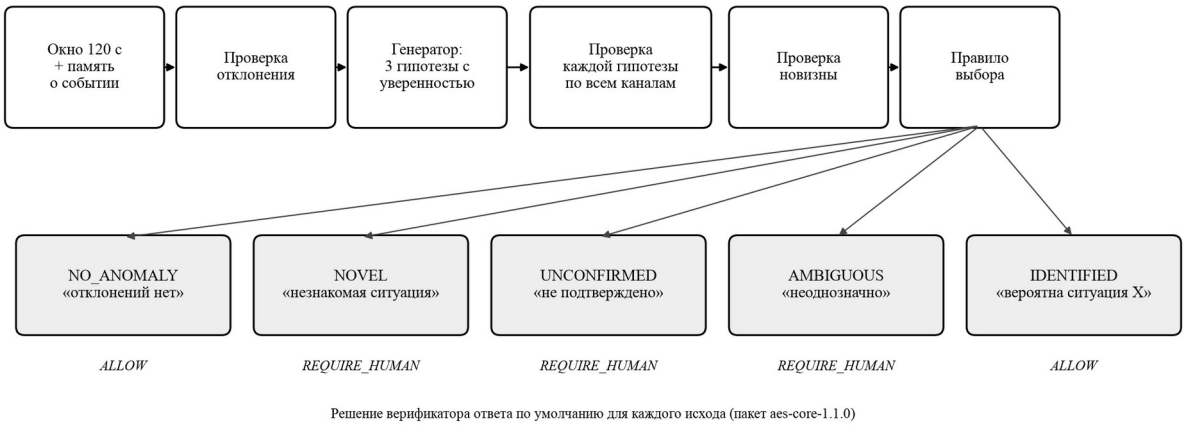


Рисунок 2 – Диагностический конвейер и исходы диагностики

Диагностический конвейер (рисунок 2) для каждого окна наблюдений выполняет проверку отклонения, формирование гипотез, их независимую проверку, проверку новизны и выбор итогового исхода.

4.1 Генератор гипотез

Генератор формирует по окну шести разрешённых каналов три наиболее вероятные гипотезы о сценарии. Для каждого канала вычисляются семь признаков окна: значение в начале и в конце окна, среднее, стандартное отклонение, минимум, максимум и наклон линейного тренда, всего 42 признака.

Сравнивались два классификатора библиотеки scikit-learn [19]: логистическая регрессия со стандартизацией признаков и градиентный бустинг на гистограммах [20] (300 итераций). Обучение выполнялось на окнах обучающей выборки. Уверенность калибровалась температурным масштабированием [21]: вероятности преобразуются по правилу $p \propto \exp(\ln p / T)$, параметр T подбирается минимизацией NLL на валидационной выборке. Модель выбиралась по NLL на валидационной выборке после калибровки (таблица 7).

Таблица 7 – Сравнение моделей генератора на валидационной выборке (12 классов, этап B)

Модель	top-1	top-3	ECE до калибровки	ECE после калибровки
логистическая регрессия	0,652	0,977	0,057	0,050
градиентный бустинг	0,786	0,998	0,055	0,029

Выбран градиентный бустинг. Значение T = 1,67 > 1 означает, что до калибровки модель была сверхуверенной; калибровка почти вдвое снизила ошибку калибровки. Языковая модель в генераторе не используется: классический классификатор детерминирован, калибруется и объясним, что соответствует требованию к этапу «мягкой интерпретации» [5].

Основные пары путаницы генератора – сценарии, физически близкие по шести каналам: течь в горячей и холодной нитке, разрывы трубок ПГ A и B, извлечение и введение стержней. Верный сценарий почти всегда входит в три гипотезы, поэтому основная задача верификатора – выбор внутри набора гипотез.

4.2 Верификатор гипотез

Верификатор независим от генератора по данным (82 наблюдаемых канала вместо 6) и по методу (квантильные сигнатуры и правила вместо обучаемого классификатора).

Сигнатуры окна. По обучающим окнам для каждого сценария и канала вычисляются квантили 1, 5, 50, 95 и 99 % двух признаков – уровня (среднее нормированное значение) и тренда (наклон на шаг), всего 164 признака. Типичным считается интервал от 5 до 95 %, допустимым – от 1 до 99 %.

Сигнатуры ранней фазы. По памяти о событии для каждого канала вычисляются изменения через 30, 60 и 120 с от начала события относительно исходного состояния (246 признаков) – по одному вектору на обучающий прогон, тем же квантильным методом. Признаки, ещё не наблюдавшиеся к текущему моменту, в проверке не участвуют.

Специфичность. Элемент матрицы специфичности spec(s, o, p) – доля окон сценария o, у которых признак p выходит за типичный интервал сценария s. Чем больше значение, тем лучше признак p отличает сценарий s от сценария o.

Контрастная проверка. Гипотеза s проверяется против конкурентов – остальных гипотез того же набора. При наличии памяти о событии для каждого конкурента o отбираются признаки с наибольшей специфичностью именно против него (попарный отбор); без памяти используется средняя специфичность по конкурентам. Для каждого отобранного признака значение в типичном интервале s даёт свидетельство «за» с весом w, за пределами допустимого – «против» с весом w, между ними – «против» с весом w/2. Доля подтверждений равна отношению суммы весов свидетельств «за» к сумме весов всех свидетельств (таблица 8).

Таблица 8 – Параметры верификатора гипотез

Параметр	С памятью о событии	Без памяти
минимальный вес признака	0,5	0,7
порог подтверждения	0,7	0,6
порог отклонения	0,4	0,4
отбор признаков	попарный	по средней специфичности

Параметры подбирались перебором на валидационной выборке по критерию безопасности: максимум доли подтверждённых верных гипотез при доле подтверждённых неверных не более 10 %. Ложное подтверждение для АЭС опаснее неопределённости: неопределённость оставляет решение оператору, а ложное подтверждение усиливает чрезмерное доверие к автоматике [2]. При исходных параметрах верификатор подтверждал 30 % неверных гипотез; после подбора – 4 % на этапе B и 1,6 % на этапе C.

Попарный отбор введён после первого итогового прогона, в котором течь в горячей нитке в 50 % окон получала исход «неоднозначно»: признаки, отобранные по средней специфичности, отличали её от разрыва трубки ПГ, но

не от течи в холодной нитке. На валидационной выборке попарный отбор повысил долю установленных течей в горячей нитке с 48 до 97 %. Без памяти о событии попарный отбор подтверждал 25 % неверных гипотез, поэтому для этого случая сохранён прежний метод.

Каждое свидетельство содержит ссылку на канал и окно, наблюдаемое значение, ожидаемый интервал и вес, например: «Press Partial RB air (bar): уровень +2,11σ – в типичном диапазоне для LOCA [−0,4; +2,23]».

4.3 Проверка отклонения и новизны

Верификатор оценивает согласие данных с гипотезой, но не может установить, что событие не похоже ни на один известный сценарий. На этапе В пробы вне обучаемого множества подтверждались в 69 % окон. Для решения этой задачи введены две проверки [22].

Проверка отклонения. Канал считается отклонившимся, если $|x - x_0| / \max(|x_0|, 10^{-3}) > 0{,}01$, где x_0 – значение в исходном состоянии. Четыре канала, дрейфующих и без события (HTR, RBLK, RHFL, RHMT; установлены по прогонам без события), не учитываются. Если не отклонился ни один канал, исход – «отклонений не обнаружено».

Проверка новизны. Вычисляются среднеквадратичное расстояние (с робастной нормировкой, только по уже наблюдённым признакам) от признаков ранней фазы текущего события до ближайшего обучающего события и евклидово расстояние от признаков окна до ближайшего обучающего окна. Порог каждого расстояния – 99-й перцентиль на валидационной выборке (1,312 и 6,093). Событие признаётся новым, если превышен любой порог; суммарная доля ложных тревог на известных сценариях валидационной выборки – 2,0 %.

4.4 Итоговое правило выбора

Исход диагностики окна определяется правилом:

1) нет отклонения – NO_ANOMALY («отклонений не обнаружено»);

2) событие новое – NOVEL («ситуация не похожа ни на один известный сценарий»);

3) нет подтверждённых гипотез – UNCONFIRMED («не подтверждено»);

4) подтверждена одна гипотеза или лидер опережает вторую подтверждённую по доле подтверждений не менее чем на 0,1 – IDENTIFIED («вероятна ситуация X»);

5) иначе – AMBIGUOUS («неоднозначно»).

Сведения приведены в таблице 9.

Таблица 9 – Выбор допуска итогового правила на валидационной выборке

Допуск	**Точность исхода IDENTIFIED**	**Доля окон с исходом IDENTIFIED**
0	0,978	0,923
0,05	0,995	0,886
0,1	0,996	0,882
0,2	0,996	0,847
0,3	0,996	0,823

Выбран допуск 0,1: при дальнейшем увеличении точность не растёт, а доля диагнозов снижается.

4.5 Подбор аналогов

Для каждого сценария NPPAD в конфигурации заданы типы исходного события базы ETHZ (например, для разрыва трубки ПГ – Steam Generator Tube Rupture, для течей – SBLOCA, MBLOCA, LBLOCA), текстовый запрос и системы-источники. События с совпавшим типом исходного события ранжируются первыми; затем выдача дополняется текстовым поиском BM25 [23] по словам и словосочетаниям описания, системы и причины события, с повышающим коэффициентом 1,5 при совпадении системы и порогом оценки 3,0. Дубли (одно событие на нескольких энергоблоках) удаляются. Аналог формулируется как справка «в аналогичных случаях наблюдалось…» без предписания действий. Реализация BM25 используется также в памяти

ассистента вместо поиска по подстроке, что устранило расхождение с отчётом 6-го семестра.

5 Верификация ответа и интеграция с ассистентом

5.1 Верификатор ответа

Верификатор ответа реализует схему «утверждение – свидетельство – набор правил – решение политики» и располагается между агентами ассистента и пользователем. Каждый агент передаёт вместе с текстом список утверждений со ссылками на свидетельства: агент поиска – на найденные фрагменты базы знаний, агент выполнения кода – на запись журнала запусков, агент-аналитик – на собственный текст, диагностический ответ – на окна и каналы телеметрии, события ETHZ и фрагменты базы знаний.

Доверие к источнику задаёт политика по виду источника, а не агент: подтверждение человека – 1,0, нормативный документ – 0,95, телеметрия – 0,9, вывод инструмента – 0,8, фрагмент базы знаний – 0,7, историческое событие – 0,6, текст модели – 0,2. Сила утверждения равна минимуму доверия по его свидетельствам, уверенность ответа – минимуму силы утверждений (таблица 10).

Таблица 10 – Правила пакета aes-core-1.1.0

Правило	Уровень	Проверка
EVIDENCE_REQUIRED	ошибка	есть хотя бы одно утверждение, и у каждого есть ссылка
NO_MODEL_ONLY	предупреждение	нет утверждений, опирающихся только на текст модели
REF_RESOLVABLE	ошибка	каждая ссылка разрешается в существующий артефакт
DIAGNOSIS_CONFIRMED	предупреждение	диагноз без оговорки выпускается только при исходах IDENTIFIED и NO_ANOMALY
NO_DIRECTIVES	ошибка	в ответе нет указаний к действию

Нарушение правила уровня «ошибка» приводит к решению BLOCK – вместо ответа выдаётся безопасная заглушка. Нарушение предупреждения или уверенность ниже 0,5 – к решению REQUIRE_HUMAN: ответ выпускается с пометкой «требуется оценка оператора» и перечнем причин. Иначе принимается решение ALLOW. Разрешимость ссылок проверяют источники

данных: окна – источник телеметрии, события – база ETHZ, фрагменты – векторная память, запуски кода – журнал исполнителя. Пакет правил версионируется; первая версия (aes-core-1.0.0, три правила) сохранена для воспроизводимости ранних результатов.

5.2 Режимы работы

Чтобы не изменить поведение базового ассистента (требование 1), введены три режима проверки. В режиме off проверки нет. В режиме shadow (по умолчанию для чата) решение вычисляется и записывается в трассу, а текст не меняется. В режиме enforce решения применяются, и в память диалога записывается только выпущенный текст. Диагностический ответ всегда проверяется в режиме enforce. Такое поэтапное включение новых защитных слоёв соответствует рекомендациям анализа развития системы [5].

5.3 Диагностический ответ

Метод explain_diagnosis агента-аналитика строит ответ из итогов диагностики детерминированно: оценка ситуации; гипотезы со статусами проверки и долями подтверждений; свидетельства с метками [E1], [E2] и ссылками на окно и канал; аналоги ETHZ с метками [A1]; для установленного сценария – справка из базы знаний с меткой [D1]; завершающая фраза о том, что решение о действиях принимает оператор. Каждая фраза оформляется как утверждение со ссылками. Пример ответа приведён в приложении Б.

По запросу языковая модель добавляет краткое пояснение. Оно разбирается по предложениям: предложение со ссылками опирается на соответствующие свидетельства, предложение без ссылок – только на текст модели, ссылка на несуществующее свидетельство нарушает правило REF_RESOLVABLE. Если пояснение приводит к блокировке ответа, оно отбрасывается, детерминированная часть проверяется повторно и выпускается с пометкой «Пояснение языковой модели не выпущено…»; отклонённое

пояснение сохраняется в трассе для аудита. Так ошибка необязательного компонента не лишает оператора проверенной диагностики.

5.4 Справка по сценариям

Ответ должен ссылаться на документацию, однако база знаний прототипа не содержала документов по аварийным сценариям. Справка по каждому обучаемому сценарию построена автоматически из журналов событий симулятора обучающих прогонов: какие действия систем станции происходят, в какой доле прогонов и в какое время (медиана и межквартильный размах) (таблица 11).

Таблица 11 – Фрагмент справки по сценарию LOCA (60 обучающих прогонов)

Событие	**Доля прогонов**	**Время, медиана**
сигнал АЗ по низкому давлению первого контура	95 %	125 с
аварийная остановка реактора	100 %	126 с
включение насосов высоконапорного впрыска	100 %	133 с
запуск спринклерной системы защитной оболочки	100 %	159 с
закрытие отсечных клапанов питательной воды	78 %	304 с
оголение активной зоны	47 %	16 мин
переход на рециркуляцию из приямка	98 %	49 мин

Справка описательна и не содержит указаний к действию; фрагменты, содержащие такие указания, в ответ не допускаются. Справка загружается в память ассистента и в векторную базу с меткой сценария, а ответ ссылается только на справку установленного сценария. Это описание поведения модели энергоблока в симуляторе, а не эксплуатационная документация.

5.5 Трассировка и программный интерфейс

Метод diagnose оркестратора принимает источник телеметрии и момент времени, выполняет диагностический конвейер, строит и проверяет ответ. Источник телеметрии воспроизводит прогон только на чтение и выдаёт окно, завершившееся не позже запрошенного момента; запрос раньше конца

первого окна отклоняется, чтобы не показать данные из будущего. Программный интерфейс предоставляет метод POST /diagnose с параметрами «прогон» и «момент времени».

В Langfuse [10] записывается трасса atomic.diagnose со спанами этапов (гипотезы генератора, проверка, новизна, справка) и метаданными: полный пакет проверки (утверждения, результаты правил, решение, версия пакета правил), исход, версии моделей, задержки этапов. По трассе восстанавливается путь «данные – гипотеза – проверка – ответ – решение»; это подтверждено выгрузкой живой трассы через программный интерфейс Langfuse (таблица 12).

Таблица 12 – Путь диагностики, восстановленный по трассе Langfuse

Звено	**Значение в трассе**
данные	окно 00f89e960b2f3947 (валидационный прогон LOCA)
гипотезы генератора	LOCAC, LOCA, LLB
проверка	LOCAC – не определено, LOCA – подтверждена, LLB – отклонена
новизна	нет
справка	dataset/scenarios/LOCA.txt
исход	IDENTIFIED
утверждений в пакете проверки	8
решение	ALLOW, пакет aes-core-1.1.0

6 Программная реализация

6.1 Технологии и структура

Система реализована на Python 3.12 с использованием scikit-learn, NumPy, FastAPI [24], PostgreSQL с pgvector [8], Ollama [9] и Langfuse; зависимости зафиксированы менеджером uv [11]. Объём кода вырос с 1694 до 8786 строк: 60 модулей пакета, 18 скриптов и 21 файл тестов (таблица 13).

Таблица 13 – Основные модули

Модуль	Назначение
atomic/contracts	контракты диагностического контура и верификатора ответа
atomic/knowledge	граф знаний и функции его наполнения
atomic/diagnostics	загрузка NPPAD, барьер, генератор, сигнатуры, верификатор гипотез, новизна, начало события, аналоги, конвейер, источники телеметрии
atomic/verification	правила, разрешение ссылок, политика, верификатор ответа
atomic/agents	агенты ассистента и построение диагностического ответа
atomic/orchestration	оркестратор с методами ask, ask_verified и diagnose
atomic/memory	память диалога, векторная память, BM25, справка по сценариям
config	реестр каналов, параметры диагностики, соответствие сценариев и событий, пакеты правил
scripts	подготовка данных, обучение, оценка, демонстрация, выгрузка трассы

Параметры – разрешённые каналы, окна, разбиение, пороги верификатора, новизны и начала события, допуск правила выбора – задаются в конфигурации, а не в коде. Каждое решение с обоснованием и рассмотренными альтернативами занесено в реестр (приложение В).

6.2 Воспроизводимость

Воспроизводимость обеспечивается фиксированными версиями зависимостей и интерпретатора, конфигурацией с хэшами, фиксированным начальным значением генератора случайных чисел и коммитом источника данных в манифесте. К каждому результату прилагается паспорт версий:

версии генератора, верификатора, детектора новизны и пакета правил, хэши конфигурации и списка зависимостей, версии Python и библиотек, цифровые отпечатки моделей Ollama. Данные и модели не хранятся в системе контроля версий, а восстанавливаются скриптами.

6.3 Тестирование

Тесты разделены на уровни, предусмотренные дорожной картой (таблица 14).

Таблица 14 – Уровни тестирования

Уровень	Что проверяется	Режим
регрессия базового ассистента	маршрутизация, выполнение кода, поиск по базе знаний	быстрый, с Ollama
модульные	загрузчик, контракты, граф, генератор, сигнатуры, верификатор, новизна, начало события, аналоги, BM25, правила и политика	быстрый
контрактные	информационный барьер; ответ без данных для проверки не выпускается как обычный	быстрый
сквозные	окно NPPAD – гипотезы – проверка – ответ – решение; программный интерфейс	быстрый
качество текста	релевантность ответа по оценке модели-судьи	полный

Модульные тесты используют синтетический набор в формате NPPAD и не зависят от языковой модели и базы данных. Итоговый прогон: 130 тестов быстрого режима и 2 теста полного режима проходят.

7 Экспериментальная оценка

7.1 Методика

Оценка выполняется отдельным скриптом – единственным компонентом, имеющим доступ к истинным меткам. Тестовая выборка (222 прогона, 13 984 окна, 11 классов) не использовалась для обучения и подбора параметров. Метрики: для генератора – доля окон с верным сценарием на первом месте (top-1) и среди трёх гипотез (top-3), ошибка калибровки ECE и NLL; для верификатора – доли подтверждённых верных и неверных гипотез; для итогового правила – распределение исходов, доля окон с исходом IDENTIFIED (покрытие) и его точность; для проверки ответа – распределение решений и число выпущенных испорченных ответов; для поиска – precision@k и recall@k; задержка этапов; совпадение результатов повторных прогонов.

Две проблемы были обнаружены на тестовой выборке (неразличимость малых течей в горячей нитке) и на стресс-тесте (ложная идентификация нормального снижения мощности). Исправления разрабатывались и настраивались только на валидационной выборке; приводимые итоговые числа получены на замороженной версии системы, но не являются полностью независимой оценкой.

7.2 Генерация гипотез

Результаты приведены в таблице 15.

Таблица 15 – Качество генератора гипотез на тестовой выборке

Показатель	Значение
top-1	0,888
top-3	0,996
ECE до / после калибровки	0,048 / 0,028
NLL после калибровки	0,221

7.3 Проверка гипотез и итоговые исходы

Результаты приведены в таблице 16.

Таблица 16 – Качество проверки гипотез на тестовой выборке

Показатель	Первый прогон	Итог	Без памяти о событии
верных гипотез подтверждено	0,947	0,969	0,687
неверных гипотез подтверждено	0,050	0,015	0,041
верный сценарий первым после проверки	0,978	0,994	0,847
доля окон с исходом IDENTIFIED	0,888	0,952	0,623
точность исхода IDENTIFIED	0,9985	0,9989	0,985
неверные диагнозы от всех окон	0,0014	0,0010	0,0091

В итоговом прогоне исходы распределились так: IDENTIFIED – 95,2 %, UNCONFIRMED – 3,1 %, NOVEL – 1,4 %, AMBIGUOUS – 0,3 %, NO_ANOMALY – 0,04 %. Память о событии повышает долю диагнозов с 0,62 до 0,95 и снижает долю неверных диагнозов в девять раз. Результаты с причинным определением начала события совпадают с результатами при начале события в момент начала записи: на всех тестовых окнах найденное начало совпало с ним (таблица 17).

Таблица 17 – Итоговые исходы по классам на тестовой выборке

Класс	IDENTIFIED	Точность	UNCONFIRMED	NOVEL
FLB	0,981	1,000	0,000	0,013
LLB	0,985	1,000	0,015	0,000
LOCA	0,957	1,000	0,007	0,036
LOCAC	0,962	1,000	0,021	0,017
LR	0,898	1,000	0,092	0,010
RI	0,929	1,000	0,011	0,060
RW	0,877	0,974	0,108	0,004
SGATR	0,982	1,000	0,001	0,007
SGBTR	0,986	1,000	0,001	0,004
SLBIC	0,888	0,999	0,069	0,043
SLBOC	0,962	1,000	0,037	0,000

Течь в горячей нитке в первом прогоне устанавливалась лишь в 46 % окон (в 50 % исход был «неоднозначно»); после введения попарного отбора – в 96 %, без ошибочных определений.

7.4 Ситуации вне обучаемого множества и проверка новизны

Результаты приведены в таблице 18.

Таблица 18 – Поведение системы на пробах вне обучаемого множества

Проба	Группа	Окон	Ожидаемый исход	Доля ожидаемого исхода
ATWS	события нет	95	NO_ANOMALY	1,00
MD	события нет	9697	NO_ANOMALY	1,00
SP	события нет	84	NO_ANOMALY	1,00
LACP	вне области	83	NOVEL	1,00
LOF	вне области	84	NOVEL	1,00
Normal	вне области	49	NOVEL	1,00
TT	вне области	119	NOVEL	1,00

Ни в одном окне проб не поставлен диагноз IDENTIFIED (на этапе B хотя бы одна гипотеза подтверждалась в 69 % окон проб). Ложные тревоги новизны на известных сценариях тестовой выборки – 1,4 %.

Предел проверки новизны оценён по схеме «исключить один класс»: класс удалялся из эталона детектора, после чего определялась доля его окон, признанных новыми. В среднем она составила 43 % при 1,4 % ложных тревог на остальных классах. Хорошо отделяются LLB, LR, RI и SLBIC (89–100 %), почти не отделяются LOCA и LOCAC (каждая похожа на другую), RW, SGATR и SLBOC (0–12 %). Сценарий, физически близкий к известному, по данным от него неотличим – это свойство метода.

7.5 Внешний стресс-тест

Результаты приведены в таблице 19.

Таблица 19 – Результаты на прогонах с изменением мощности

Показатель	Начало события из описания прогона	Причинное определение начала
ложные IDENTIFIED до ввода неисправности (296 окон)	0,037	0
неверные IDENTIFIED после ввода (320 окон)	0,003	0
верные IDENTIFIED после ввода	0	0

Нормальные изменения мощности и аварии на их фоне получают исход NOVEL: режимов с мощностью ниже 100 % в обучающих данных нет, и система сообщает о незнакомой ситуации вместо диагноза. Использование момента ввода неисправности из описания прогона приводило к ложной идентификации нормального снижения мощности как сброса нагрузки в 18 % окон; причинное определение начала события с защёлкой устранило эту ошибку.

7.6 Верификатор ответа

Проверены детерминированные ответы для каждого 25-го окна тестовой выборки (560 ответов) и по три испорченные версии каждого из них (таблица 20).

Таблица 20 – Результаты верификатора ответа

Показатель	Значение
ALLOW / REQUIRE_HUMAN / BLOCK	0,952 / 0,048 / 0
ответов со справкой по сценарию	533 из 560
испорченные ответы без ссылок – заблокировано	560 из 560
испорченные ответы со ссылкой на несуществующее окно – заблокировано	560 из 560
испорченные ответы с указанием к действию – заблокировано	560 из 560
испорченных ответов выпущено как ALLOW	0

Все решения REQUIRE_HUMAN приходятся на неуверенные исходы: UNCONFIRMED (19), NOVEL (7), AMBIGUOUS (1).

7.7 Пояснения языковой модели

Пояснения модели qwen2.5-7B оценивались на 13 случаях (по одному тестовому окну каждого класса и пробы TT, MD) в трёх прогонах. Указаний к действию не было ни в одном из 39 пояснений. Доля предложений со ссылками составила 0,79, 0,91 и 0,74; число ответов с решением ALLOW – 4, 11 и 4 из 13. Ответы модели недетерминированы: при одинаковом входе они

существенно различаются, поэтому воспроизводима только детерминированная часть ответа. В первом прогоне два пояснения со ссылками на несуществующие свидетельства блокировали весь ответ; после введения отката к детерминированному ответу блокировок нет.

Качество текста дополнительно оценивалось языковой моделью-судьёй [12] через библиотеку deepeval [13]; судья – модель другого семейства (vikhr-llama3.1-8b), чем автор пояснений (таблица 21).

Таблица 21 – Оценка пояснений моделью-судьёй

Набор	Верность отчёту	Релевантность
пояснения системы, среднее (13 случаев)	0,71	0,76
контроль: верное пояснение	0,67	0,50
контроль: искажённое пояснение	0,33	1,00

Метрика верности различает верное и искажённое пояснения, метрика релевантности на правдивость не реагирует. Оценка моделью-судьёй грубая и используется только как вспомогательная; выпуск ответа определяют детерминированные правила.

7.8 Поиск аналогов

Результаты приведены в таблице 22.

Таблица 22 – Качество подбора аналогов (средние по 16 сценариям)

Режим	P@3	P@10	P@20	R@3	R@10	R@20
текстовый (BM25)	0,68	0,54	0,56	0,09	0,20	0,35
совмещённый	0,93	0,81	0,77	0,36	0,48	0,65

Релевантным считается событие, тип исходного события которого соответствует сценарию. Совмещённый режим использует то же поле, что и разметка, поэтому его оценка завышена по построению; независимой мерой качества поиска служит текстовый режим. Низкая полнота объясняется большим числом релевантных событий (например, 124 события типа Transient) при выдаче трёх аналогов.

7.9 Производительность и воспроизводимость

Результаты приведены в таблице 23.

Таблица 23 – Задержка этапов диагностического контура (300 окон)

Этап	Медиана, мс	95-й перцентиль, мс
генератор	17,8	33,3
верификатор гипотез	4,8	5,7
проверка новизны	3,0	3,8
весь контур с подбором аналогов	25,8	42,8

При шаге данных 10 с запас производительности превышает два порядка. Пояснение языковой модели занимает десятки секунд, поэтому оно необязательно и по умолчанию отключено.

Воспроизводимость проверена дважды. Повторный прогон оценки на той же версии дал полностью совпадающие метрики. Сборка из чистого окружения (новая копия репозитория, установка зависимостей по зафиксированному списку, подготовка данных и обучение всех моделей заново) дала совпадающие метрики и паспорт версий. При первой такой сборке выяснилось, что версия интерпретатора не была закреплена (использовался Python 3.14); метрики совпали и в этом случае, после чего версия была закреплена.

7.10 Ограничения

Результаты получены при следующих ограничениях:

– данные – симуляция PCTRAN для одного типа PWR, все прогоны начинаются со 100 % мощности; при другой мощности система отвечает «незнакомая ситуация»;
– новый сценарий, физически близкий к известному, проверкой новизны не отличается (43 % по схеме «исключить один класс»);
– класс SLBOC различим только по мониторам радиации;

– плановое изменение мощности остаётся событием до возврата к исходному уровню, что даёт исход NOVEL и требует оценки оператора;
– справка по сценариям описывает поведение модели энергоблока в симуляторе;
– тестовая выборка и стресс-тест использовались для выявления трёх проблем, исправления которых настраивались на валидационной выборке;
– пояснения языковой модели недетерминированы.

ЗАКЛЮЧЕНИЕ

В ходе производственной практики прототип интерактивного ассистента для операторов АЭС, созданный в 6-м семестре, развит до системы поддержки принятия решений на основе формирования и верификации гипотез о состоянии энергоблока. Выполнены этапы A, B, C и E технической дорожной карты; система заморожена.

Получены следующие результаты.

1) Разработана модель данных: реестр 96 каналов с разметкой подсистем и каналов-подсказок, воспроизводимый конвейер подготовки NPPAD с разбиением по прогонам и нормализацией по обучающей выборке, окна наблюдений и причинная память о событии с защёлкой, типизированные контракты, граф знаний с проверяемой схемой и трёхуровневый информационный барьер. Аудит данных выявил классы NPPAD без наблюдаемого события, что учтено в составе обучаемых классов.

2) Разработан генератор калиброванных гипотез по шести каналам критических функций безопасности: верный сценарий первым в 88,8 % окон и среди трёх гипотез в 99,6 % окон тестовой выборки при ошибке калибровки 0,028.

3) Разработан независимый верификатор гипотез по 82 каналам на основе квантильных сигнатур окна и ранней фазы с попарным отбором признаков: подтверждается 96,9 % верных и 1,5 % неверных гипотез. Память о начале события решила задачу различения течей в горячей и холодной нитке.

4) Введены проверки отклонения и новизны и итоговое правило выбора: диагноз ставится в 95,2 % окон с точностью 99,9 %, на всех семи пробах вне обучаемого множества получен ожидаемый исход без ложных диагнозов, на стресс-тесте с изменением мощности ложных диагнозов нет.

5) Реализован детерминированный верификатор ответа по схеме «утверждение – свидетельство – набор правил – решение политики» с моделью доверия к источникам и пятью правилами, в том числе запретом

указаний к действию. Все 1680 контрольных испорченных ответов заблокированы.

6) Диагностический контур интегрирован с агентом-аналитиком: ответ строится со ссылками на телеметрию, исторические события и справку по сценарию; пояснение языковой модели проверяется по предложениям и при нарушении правил отбрасывается. Трасса Langfuse позволяет восстановить путь от данных до решения.

7) Проведены компонентное, контрактное и сквозное тестирование (130 тестов быстрого режима и 2 полного) и оценка на отложенной выборке; результаты воспроизводятся при повторном прогоне и при сборке из чистого окружения.

Все тринадцать требований задания выполнены (приложение А). Инварианты системы поддержки оператора соблюдены: система только читает данные, ничем не управляет, не выдаёт рекомендаций действий и оставляет решение оператору.

Основные ограничения связаны с симуляционным характером данных, единственной рабочей точкой по мощности и принципиальной неотличимостью нового сценария от физически близкого известного. Направления дальнейшей работы в рамках выпускной квалификационной работы: подтверждение оператором нового исходного состояния при плановых изменениях режима, расширение базы знаний документацией по аварийным сценариям с указанием источников, проверка на данных других рабочих точек.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1) Safety of Nuclear Power Plants: Design : Specific Safety Requirements No. SSR-2/1 (Rev. 1). – Vienna : International Atomic Energy Agency, 2016. – 71 p. – (IAEA Safety Standards Series).

2) Parasuraman R., Riley V. Humans and automation: use, misuse, disuse, abuse // Human Factors. – 1997. – Vol. 39, № 2. – P. 230–253.

3) Шелманова Е. О. Разработка интерактивного ассистента для операторов АЭС : отчёт по учебной практике (6 семестр) / рук. А. О. Толоконский ; НИЯУ МИФИ, ИФТИС, кафедра «Автоматика». – Москва, 2026.

4) Lewis P., Perez E., Piktus A. [et al.]. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. – 2020. – Vol. 33. – P. 9459–9474.

5) Upgrade to Guided Operations: эволюция системы поддержки оператора и анализ опасностей : рабочий документ проекта atomic. – 2026. – Не опубликовано.

6) Бакалаврский диплом: техническая дорожная карта : рабочий документ проекта atomic. – 2026. – 12 с. – Не опубликовано.

7) Corcoran W. R., Porter N. J., Church J. F. [et al.]. The critical safety functions and plant operation // Nuclear Technology. – 1981. – Vol. 55, № 3. – P. 690–712.

8) pgvector: Open-source vector similarity search for Postgres : репозиторий. – URL: https://github.com/pgvector/pgvector (дата обращения: 24.10.2026).

9) Ollama : документация. – URL: https://ollama.com (дата обращения: 24.10.2026).

10) Langfuse Documentation : open source LLM engineering platform. – URL: https://langfuse.com/docs (дата обращения: 25.10.2026).

11) uv: An extremely fast Python package and project manager : документация / Astral. – URL: https://docs.astral.sh/uv/ (дата обращения: 24.10.2026).

12) Zheng L., Chiang W.-L., Sheng Y. [et al.]. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena // Advances in Neural Information Processing Systems. – 2023. – Vol. 36.

13) DeepEval: The LLM Evaluation Framework : репозиторий / Confident AI. – URL: https://github.com/confident-ai/deepeval (дата обращения: 25.10.2026).

14) Kelly T., Weaver R. The Goal Structuring Notation – A Safety Argument Notation // Proceedings of the Dependable Systems and Networks 2004 Workshop on Assurance Cases. – 2004.

15) Qi B., Xiao X., Liang J. [et al.]. An open time-series simulated dataset covering various accidents for nuclear power plants // Scientific Data. – 2022. – Vol. 9. – Art. 766. – DOI 10.1038/s41597-022-01879-1.

16) PCTRAN – Personal Computer Transient Analyzer : официальный сайт / Micro-Simulation Technology. – URL: https://www.microsimtech.com (дата обращения: 24.10.2026).

17) Ayoub A., Stankovski A., Kröger W., Sornette D. The ETH Zurich curated nuclear events database: Layout, event classification, and analysis of contributing factors // Reliability Engineering and System Safety. – 2021. – Vol. 213. – Art. 107781. – DOI 10.1016/j.ress.2021.107781.

18) Ayoub A., Stankovski A., Kröger W., Sornette D. Precursors and startling lessons: Statistical analysis of 1250 events with safety significance from the civil nuclear sector // Reliability Engineering and System Safety. – 2021. – Vol. 214. – Art. 107820. – DOI 10.1016/j.ress.2021.107820.

19) Pedregosa F., Varoquaux G., Gramfort A. [et al.]. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. – 2011. – Vol. 12. – P. 2825–2830.

20) Friedman J. H. Greedy function approximation: a gradient boosting machine // The Annals of Statistics. – 2001. – Vol. 29, № 5. – P. 1189–1232.

21) Guo C., Pleiss G., Sun Y., Weinberger K. Q. On Calibration of Modern Neural Networks // Proceedings of the 34th International Conference on Machine Learning. – 2017. – P. 1321–1330.

22) Hendrycks D., Gimpel K. A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks // International Conference on Learning Representations (ICLR). – 2017.

23) Robertson S., Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond // Foundations and Trends in Information Retrieval. – 2009. – Vol. 3, № 4. – P. 333–389.

24) FastAPI : документация. – URL: https://fastapi.tiangolo.com (дата обращения: 24.10.2026).

ПРИЛОЖЕНИЕ А

(обязательное)

Соответствие результатов требованиям задания

Сведения приведены в таблице 24.

Таблица 24 – Выполнение технических требований задания

№	Требование	Реализация	Результат
1	Сохранить работоспособность базового ассистента	регрессионные тесты, режим shadow верификатора	регрессия проходит на всех этапах
2	Загрузка и нормализация NPPAD	загрузчик, реестр каналов, манифест	одна команда, 15 с
3	Единая семантическая модель	граф знаний, контракты	схема связей проверяется
4	Гипотезы по разрешённым каналам	генератор по 6 каналам, калибровка	top-1 0,888, top-3 0,996
5	Генератор не видит скрытых данных	трёхуровневый барьер	контрактные тесты проходят
6	Независимая проверка по полному набору каналов	верификатор по 82 каналам, новизна	неверных подтверждено 0,015
7	Свидетельства и аналоги	свидетельства со ссылками, аналоги ETHZ	P@3 0,68 (текст)
8	Передача гипотез в конвейер ассистента	explain_diagnosis, diagnose, POST /diagnose	сквозные тесты проходят
9	Детерминированная проверка ответа	пакет правил aes-core-1.1.0, политика	0 из 1680 испорченных выпущено
10	Трассируемость и аудит	трасса Langfuse с пакетом проверки	путь восстанавливается
11	Компонентное и сквозное тестирование	130 + 2 теста	все проходят
12	Оценка качества	скрипт оценки на тестовой выборке	раздел 7
13	Воспроизводимость	фиксированные версии, паспорт, повторные прогоны	совпадение, в том числе из чистого окружения

ПРИЛОЖЕНИЕ Б

(справочное)

Пример ответа оператору

Ниже приведён ответ системы для окна 180–290 с валидационного прогона течи в горячей нитке (тяжесть 95 %), сокращённый: перечень свидетельств оставлен частично.

```
Оценка ситуации (окно 180–290 с): Вероятна ситуация LOCA (течь теплоносителя,
горячая нитка): подтверждена независимой проверкой, 100% взвешенных свидетельств «за».


Гипотезы (генератор по 6 каналам → проверка по всем наблюдаемым каналам):
  1. LOCA (течь теплоносителя, горячая нитка) — уверенность генератора 65%;
     проверка: подтверждена, доля подтверждений 100% (за 14, против 0) [E1]...[E5]
  2. LOCAC (течь теплоносителя, холодная нитка) — уверенность генератора 34%;
     проверка: не определено, доля подтверждений 53% (за 10, против 11) [E6]...[E15]
  3. SGBTR (разрыв трубки ПГ B) — уверенность генератора 0%;
     проверка: отклонена, доля подтверждений 0% (за 0, против 21) [E16]...[E20]


Свидетельства:
  [E1] Press Partial RB air (bar): уровень +2.11σ — в типичном диапазоне для LOCA
       [-0.4; +2.23] (ссылка f141a767f35b2909#PRBA)
  [E11] Temp RCS average (°C): изменение за 30 с от начала события -0.000907σ —
       вне допустимого диапазона для LOCAC [-0.000763; -0.000763]
       (ссылка 29da0e3744321186#TAVG)
  ...


Справочные материалы базы знаний по LOCA:
  [D1] «сигнал АЗ по низкому давлению первого контура — 95 % прогонов; 125 с ...»
       (dataset/scenarios/LOCA.txt)


Система только интерпретирует данные; решение о действиях принимает оператор.


Решение верификатора ответа: ALLOW (пакет aes-core-1.1.0, нарушений нет,
уверенность 0,60)
```

ПРИЛОЖЕНИЕ В

(справочное)

Перечень проектных решений

Полный реестр с контекстом, обоснованием и альтернативами ведётся в документации проекта (docs/decisions.md) (таблица 25).

Таблица 25 – Проектные решения

№	Решение
D-001	базовая версия помечена тегом, разработка в отдельной ветке
D-002	бинарные материалы и данные вне системы контроля версий
D-003	источник NPPAD – CSV из репозитория авторов
D-004	однопрогонные классы – пробы, а не обучаемые классы
D-005	явное исключение лишних столбцов SLBIC
D-006	шесть разрешённых каналов по критическим функциям безопасности
D-007	каналы-подсказки исключены из генератора и верификатора
D-008	окна 120 с со сдвигом 60 с
D-009	граф знаний в памяти с проверяемой схемой
D-010	конфигурация в TOML
D-011	разбиение 60/20/20 по прогонам, нормализация по обучению
D-012	непрозрачные идентификаторы
D-013	тяжесть из журнала симулятора
D-014	режимы верификатора off, shadow, enforce
D-015	доверие к источнику назначает политика
D-016	одно утверждение на ответ агента обычного чата
D-017	пустой результат поиска – REQUIRE_HUMAN
D-018	тесты не отправляют трассы
D-019	генератор – классический классификатор без языковой модели
D-020	фильтр базы ETHZ: энергоблоки PWR
D-021	подбор аналогов: BM25 и таблица соответствия
D-022	параметры верификатора подобраны по критерию безопасности
D-023	контрастная проверка гипотез
D-024	хэш конфигурации данных по разделам, влияющим на данные
D-025	тестовая выборка не используется до итоговой оценки
D-026	BM25 в памяти ассистента
D-027	инструмент ETHZ воспроизведён на Python
D-028	аналоги по типу исходного события
D-029	Variable_Power_Data – внешний стресс-тест

№	Решение
D-030	память о событии и сигнатуры ранней фазы
D-031	параметры верификатора с памятью и без
D-032	проверки отклонения и новизны
D-033	итоговое правило выбора
D-034	классы без наблюдаемого события исключены из обучаемых
D-035	пакет правил aes-core-1.1.0
D-036	детерминированный диагностический ответ и проверяемое пояснение
D-037	удаление материалов оппонентов из истории репозитория
D-038	попарный отбор признаков
D-039	причинное определение начала события
D-040	ссылки на базу знаний в диагностическом ответе
D-041	откат к детерминированному ответу при блокировке пояснения
D-042	защёлка события до возврата к исходному состоянию
D-043	справка по сценариям из журналов симулятора
D-044	исправленные дефекты этапа доводки