Национальный исследовательский ядерный университет «МИФИ»
Институт физико-технических интеллектуальных систем (ИФТИС)
Кафедра **«Автоматика»**

ОТЧЕТ ПО ЗАДАНИЮ НА УЧЕБНУЮ ПРАКТИКУ

по направлению подготовки: Системный анализ и управление. Информационно-измерительные и управляющие системы киберфизических устройств и установок.

Выполнил(а): Шелманова Ева Олеговна
Группа: Б23-605

Руководитель практики: Толоконский Андрей Олегович, к.т.н., доцент кафедры “Теплофизика"

г. Москва
2026

Задание на учебную практику (ознакомительную) (6 семестр)

Студент:	Шелманова Ева Олеговна	Группа	Б23-605
Тема:	Разработка интерактивного ассистента для операторов АЭС		

1. Исходные данные

1.1. Объект исследования

Операционный информационный поток и нормативно-техническая документация АЭС: операционные процедуры, аварийные инструкции, регламенты, справочные таблицы.

1.2. Предмет исследования (разработки)

Прототип распределённой RAG-системы в агентном оформлении для: быстрого поиска релевантных фрагментов регламентов; генерации ответов с явными ссылками на источники; автоматической верификации ответов по правилам и метрикам достоверности.

1.3. Основные технические требования, предъявляемые к исследованию (разработке)

Достоверность: ссылки на источники в каждом ответе. Трассируемость: лог всех операций. Надёжность retrieval: precision@1 ≥ порога, быстрый отклик. Модульность: разделение агентов на роли. Безопасность UI: экран «источники и ограничения», пометки low-confidence/conflict. Реплицируемость: запуск по инструкциям.

2. Содержание работы

2.1. Теоретическая часть (обзор источников по выбранной тематике; описание объекта; выбор структуры и элементной базы устройства или системы; проведение расчетов; разработка математических моделей, схем, алгоритмов, методик исследования и проектирования и т.д.)

– Обзор литературы: RAG, dense/sparse retrieval, n8n, верифицируемость LLM, агентные архитектуры, регламентные базы знаний в критичных отраслях.

– Описание объекта: информационные потоки оператора АЭС, типы документов (процедуры, регламенты, техспецификации) и запросов (информационные, процедурные, troubleshooting, emergency).

– Архитектура: парсер → chunker → embeddings → vector DB → retriever → generator → verifier → UI/API; обоснование выбора инструментов.

– Модели и алгоритмы: гибридное индексирование (dense + BM25), reranking, prompt-engineering для citation-aware генерации, верификация (шаблоны, проверки диапазонов, детектор конфликтов).

– Метрики: precision@k, recall@k, ROUGE/F1, hallucination rate, time-to-answer, usability. Безопасность: ограничения LLM, риски в критичных сценариях, human-in-the-loop.

2.2. Практическая часть (моделирование, макетирование, верификация, наладка, проведение различного рода испытаний и т.д.)

– Корпус документов: парсинг PDF/HTML, очистка, chunking (500–1000 токенов), метаданные.

– Индекс и retrieval: embeddings + FAISS, BM25 fallback.

– Генератор ответов: LLM с prompt-шаблонами, обязательные ссылки на источники.

– Verifier-agent: unit checks, числовые диапазоны, детектор конфликтов, fact-checker.

– Оркестрация агентов: логика вызовов агентов, при конфликте – оба фрагмента с пометкой.

– Интерфейс: веб-приложение с поиском, ответом, источниками и индикатором верификации.

– Валидация: 30–80 тестовых запросов, эталонные ответы, 5–10 кейсов (штатный, аварийные, конфликты).

– Докеризация: Dockerfile, README, инструкции запуска.

3. Список источников

IAEA (нормативные документы), FAISS (векторный поиск), Hugging Face (embeddings и LLM), LangChain (оркестрация), N8N (для прототипирования агентной системы), FastAPI/Streamlit (интерфейс), Weights & Biases (трекинг), научные статьи по RAG, retrieval и verifiability.

Место выполнения практики: Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский ядерный университет «МИФИ», ИФТИС, кафедра №2 “Автоматика”.

Режим работы: понедельник, вторник: 8:30 - 18:00.

*Руководитель практики: Толоконский Андрей Олегович, к.т.н., доцент кафедры "Теплофизика"
AOTolokonskij@mephi.ru , +7-(916)-712-50-93

СОДЕРЖАНИЕ

Введение

1. Обзор существующих подходов

  1.1. Архитектура Извлечение-Augmented Generation

  1.2. Методы информационного поиска

    1.2.1. Dense извлечение

    1.2.2. Sparse извлечение

    1.2.3. Гибридные методы

  1.3. Агентные системы

  1.4. Методы обеспечения верифицируемости

  1.5. Выводы по главе

2. Анализ предметной области

  2.1. Особенности эксплуатации АЭС

  2.2. Информационные потоки

  2.3. Типы документов

  2.4. Типы пользовательских запросов

  2.5. Требования к системе

3. Разработка архитектуры системы

  3.1. Общая структура системы

  3.2. Обработка документов

  3.3. Индексация

  3.4. Поисковый модуль

  3.5. Генеративный модуль

  3.6. Модуль верификации

  3.7. Пользовательский интерфейс

4. Модели и алгоритмы

  4.1. Гибридный поиск

4.2. Ранжирование
4.3. Генерация ответов
4.4. Верификация
4.5. Обработка ошибок
5. Векторизация данных в RAG-системах
5.1. Понятие векторных представлений
5.2. Модели для векторизации текста
5.3. Процесс векторизации документов и запросов
5.4. Метрики сходства
5.5. Векторные базы данных
5.6. Индексация и ускорение поиска
5.7. Влияние качества векторизации на RAG
5.8. Ограничения и проблемы векторизации
5.9. Выводы по главе
6. Методы обработки текста для улучшения поиска
6.1. Роль предобработки текста в RAG-системах
6.2. Очистка и нормализация текстовых данных
6.3. Структурное разбиение документов (chunking)
6.4. Обогащение данных метаданными
6.5. Нормализация доменной лексики
6.6. Семантическое представление и гибридный поиск
6.7. Переранжирование результатов поиска
6.8. Оптимизация контекста для генерации
6.9. Выводы по главе
7. Метрики и оценка эффективности
7.1. Метрики поиска
7.2. Метрики генерации

7.3. Метрики надежности
7.4. Операционные метрики
8. Безопасность и ограничения
8.1. Ограничения языковых моделей
8.2. Риски применения
8.3. Методы снижения рисков
9. Использование локальных языковых моделей в критичных системах
9.1. Актуальность применения локальных моделей
9.2. Требования к локальным моделям
9.3. Архитектура использования локальных моделей
9.4. Выбор моделей и оптимизация
9.5. Управление качеством генерации
9.6. Верификация при использовании локальных моделей
9.7. Ограничения и риски
9.8. Архитектурные рекомендации
9.9. Выводы по главе
Заключение
Список литературы

ВВЕДЕНИЕ

Актуальность работы обусловлена ростом объемов технической и регламентной документации, а также необходимостью повышения качества поиска и интерпретации информации при работе с данными, относящимися к эксплуатации атомной электростанции. Для таких систем особенно важны точность, трассируемость, предсказуемость результата и возможность проверки источников информации.

Современные большие языковые модели обеспечивают высокое качество генерации текста, однако в изолированном режиме они могут допускать недостоверные утверждения, которые в критичных системах недопустимы. По этой причине применение архитектуры RAG (Извлечение-Augmented Generation – подход в ИИ, где модель сначала находит информацию, а потом генерирует ответ на её основе) представляется наиболее обоснованным, поскольку она сочетает генерацию ответа с поиском по внешним источникам знаний и может быть дополнена механизмами верификации.

Целью работы является разработка архитектуры верифицируемой RAG-системы, предназначенной для поддержки оператора атомной электростанции.

Для достижения поставленной цели необходимо решить следующие задачи:

изучить существующие подходы к извлечение (поиск и получение уже существующей информации из базы данных, документов или памяти модели) и генерация (создание нового текста (или другого контента) на основе обученной модели);

- проанализировать особенности предметной области;
- определить требования к архитектуре системы;
- описать модель векторизации и методы обработки текста;
- рассмотреть алгоритмы поиска, генерации и верификации;
- определить метрики оценки эффективности и надежности.

Объектом исследования являются процессы обработки информации в системе поддержки принятия решений. Предметом исследования выступают архитектуры интеллектуальных систем на основе RAG, применяемые в критичных областях.

Практическая значимость работы заключается в формировании структуры системы, способной обеспечивать более надежный доступ к релевантным источникам и снижать риск появления недостоверных рекомендаций. [1], [2], [3], [4]

---

1. ОБЗОР СУЩЕСТВУЮЩИХ ПОДХОДОВ

1.1. Архитектура Извлечение-Augmented Generation

Извлечение-Augmented Generation представляет собой подход, в котором генеративная модель формирует ответ не только на основе внутренних параметров, но и с опорой на внешний массив документов, извлекаемых поисковым модулем. Такая архитектура позволяет уменьшить вероятность галлюцинаций, повысить точность ответа и обеспечить ссылочную прозрачность источников.

Типовой RAG-процесс включает три основных этапа: поиск релевантных документов, формирование контекста и генерацию ответа на основе

найденных фрагментов. В зависимости от реализации система может включать дополнительные слои: ранжирование, нормализацию текста, переранжирование и верификацию.

Для критичных систем RAG особенно ценен тем, что он позволяет ограничить область генерации только доверенными источниками. При этом сам генеративный компонент не рассматривается как источник истины, а выполняет роль инструмента синтеза ответа на основании извлеченного контекста. [1], [2], [3], [4]

1.2. Методы информационного поиска

Эффективность RAG во многом зависит от качества извлечения. Поисковый модуль должен находить фрагменты, релевантные как по смыслу, так и по терминологии. В современной практике применяются dense извлечение, sparse извлечение и гибридные подходы. [1], [2], [3], [4]

1.2.1. Dense извлечение

Dense извлечение основан на представлении текста в виде векторов фиксированной размерности. Для этого используются модели embedding, которые преобразуют документы и запросы в семантическое пространство. Поиск осуществляется путем вычисления близости между векторами, чаще всего с помощью cosine similarity или dot product.

$$\cos(\theta) = \frac{A \cdot B}{\| A \| \, \| B \|}$$

A – вектор одного объекта (например, текст №1)

B – вектор другого объекта (например, текст №2)

Пример:

A = «кошка» → [0.2, -0.5, 0.8, ...]

B = «кот» → [0.21, -0.48, 0.79, ...]

Это называются эмбеддинги (числовые представления смысла)

$$\vec{A} \cdot \vec{B} = \| A \| \| B \| \cos(\theta)$$

Учитывает и угол, и длину векторов

- большой результат → вектора похожи и большие по величине
- может быть большим даже если просто большие значения

Преимуществом подхода является способность учитывать смысловую близость даже при различии формулировок. Это особенно полезно для пользовательских запросов, содержащих разговорные или неполные выражения. К недостаткам dense извлечение относится ограниченная интерпретируемость и возможные ошибки при работе с узкоспециализированной терминологией. [1], [2], [3], [4]

1.2.2. Sparse извлечение

Sparse извлечение основан на совпадении ключевых слов и терминов. Наиболее распространенным методом является BM25, который учитывает частоту слов и длину документа. Такой поиск особенно эффективен в документах с формализованной лексикой, регламентами и техническими инструкциями.

Преимущество sparse извлечение состоит в высокой точности при наличии специфических терминов и числовых обозначений. Однако он хуже работает с переформулировками и синонимами, что делает его недостаточным для

задач, где пользователь может задавать вопрос в свободной форме. [1], [2], [3], [4]

1.2.3. Гибридные методы

Гибридный поиск объединяет dense и sparse подходы. Он позволяет учитывать как смысловую близость, так и точное совпадение ключевых слов. Для предметной области атомной энергетики такой подход является наиболее рациональным, поскольку в документации одновременно присутствуют формальные фразы, коды, номера пунктов и семантически близкие описания. [1], [2], [3], [4]

1.3. Агентные системы

Агентные архитектуры используют языковую модель не только для генерации текста, но и для планирования последовательности действий: постановки подзадач, обращения к инструментам, анализа полученных результатов. Такой подход эффективен в исследовательских и информационных сценариях, однако в критичных системах требует повышенного контроля.

Основная проблема агентных систем заключается в их недетерминированности. В отличие от строго определенных инженерных модулей, агент может по-разному интерпретировать задачу и вызывать инструменты в произвольной последовательности. Поэтому для решений, применяемых в безопасности и эксплуатации, агентный подход должен быть ограничен и дополнен механизмами аудита и верификации. [1], [2], [3]

1.4. Методы обеспечения верифицируемости

Верифицируемость является ключевым требованием для систем, используемых в критичных областях. Под этим понимается возможность проверить, на каких источниках основан ответ, соответствуют ли утверждения найденным документам и нет ли в ответе противоречий.

На практике применяются следующие методы: - привязка ответа к источникам; - шаблонная генерация; - постпроверка утверждений; - ограничение домена знаний; - логический контроль структуры ответа.

Такие методы уменьшают риск выдачи неподтвержденной информации и повышают доверие к системе со стороны пользователя. [1], [2], [3]

---

2. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

2.1. Особенности эксплуатации АЭС

Работа оператора атомной электростанции связана с высокой ответственностью, строгими регламентами и ограниченным временем на принятие решений. В таких условиях недостоверная или неполная информация может привести к серьезным последствиям. Поэтому информационная система поддержки оператора должна обеспечивать не только быстрый, но и точный доступ к данным.

Для предметной области характерны формализованность процессов, наличие большого количества инструкций и необходимость соблюдения регламентированных процедур. Это означает, что система должна уметь работать с документами сложной структуры и опираться на актуальные версии нормативных материалов. [1], [2], [3]

2.2. Информационные потоки

Информационные потоки на АЭС включают оперативные данные, регламентные документы, журналы событий, аварийные инструкции и справочные материалы. Пользователю может потребоваться как быстрый доступ к фрагменту инструкции, так и поиск по целому набору документов для принятия решения в нестандартной ситуации.

Особенностью таких потоков является различие по уровню срочности и критичности. Некоторые данные предназначены для повседневной эксплуатации, другие – для аварийного реагирования. Следовательно, система должна учитывать не только смысл запроса, но и приоритет источника. [1], [2], [3]

2.3. Типы документов

В предметной области встречаются следующие типы документов:

- процедуры эксплуатации;
- технические регламенты;
- инструкции;
- журналы событий;
- справочные материалы.

Документы обладают структурой, в которой важны разделы, пункты, подпункты и перекрестные ссылки. Кроме того, они имеют версии и даты актуальности, что требует контроля применимости информации. [1], [2], [3]

2.4. Типы пользовательских запросов

Пользовательские запросы можно разделить на несколько категорий:

- информационные – поиск факта или определения;
- процедурные – поиск последовательности действий;
- диагностические – выяснение причин или условий неисправности;
- аварийные – поиск инструкций по экстренному реагированию.

Для каждой категории требуется разный режим поиска и генерации. Например, аварийный запрос должен обслуживаться максимально быстро и без лишней генерации, а процедурный – с обязательным указанием последовательности шагов и источника. [1], [2], [3]

2.5. Требования к системе

К системе предъявляются следующие ключевые требования:

- высокая точность поиска;
- объяснимость результата;
- трассируемость источников;
- надежность работы;
- поддержка актуальных версий документов;
- возможность аудита действий пользователя и системы.

Эти требования формируют основу для выбора архитектурных решений и способов обработки данных. [1], [2], [3]

---

3. РАЗРАБОТКА АРХИТЕКТУРЫ СИСТЕМЫ

3.1. Общая структура системы

Предлагаемая система образует совокупность элементов нескольких логически связанных модулей: обработки документов, индексации, поискового модуля, генеративного модуля, модуля верификации и пользовательского интерфейса. Такая структура позволяет разделить обязанности компонентов и упростить контроль качества на каждом этапе. [1], [2], [3]

3.2. Обработка документов

На этапе обработки документов выполняются синтаксический разбор исходных файлов, извлечение структуры, очистка текста, нормализация, разбиение на фрагменты и обогащение метаданными. Важно, чтобы исходная структура документа сохранялась настолько, насколько это возможно, поскольку ссылки на разделы и пункты играют важную роль в регламентных текстах. [1], [2], [3]

3.3. Индексация

Индексация включает построение двух типов представлений: лексического индекса и векторного индекса. Лексический индекс поддерживает точный поиск по ключевым словам и фразам, а векторный индекс обеспечивает семантическое сопоставление запросов и документов. [1], [2], [3]

3.4. Поисковый модуль

Поисковый модуль получает запрос пользователя, преобразует его в соответствующее представление и выполняет извлечение по нескольким каналам. Далее результаты объединяются, фильтруются и ранжируются по релевантности. Такой подход повышает полноту поиска и снижает вероятность пропуска важного источника. [1], [2], [3]

3.5. Генеративный модуль

Генеративный модуль формирует ответ на основе извлеченного контекста. Для обеспечения надежности он должен следовать шаблону, избегать добавления информации вне контекста и указывать источники, на которых основан ответ. В критичных сценариях полезно ограничить свободу генерации структурированными форматами ответа. [1], [2], [3]

3.6. Модуль верификации

Модуль верификации проверяет, соответствуют ли утверждения в ответе найденным источникам, нет ли противоречий и соблюдена ли структура ответа. При обнаружении ошибок система может либо повторно запустить поиск, либо уведомить пользователя о недостаточности данных. [1], [2], [3]

3.7. Пользовательский интерфейс

Пользовательский интерфейс должен обеспечивать отображение не только самого ответа, но и списка источников, по которым он был сформирован. Это необходимо для повышения доверия и возможности последующей проверки. Дополнительно рекомендуется вести журнал запросов, найденных документов и действий системы. [1], [2], [3], [4]

---

4. МОДЕЛИ И АЛГОРИТМЫ

4.1. Гибридный поиск

Гибридный поиск объединяет результаты dense и sparse извлечение. Сначала выполняется быстрый поиск по нескольким стратегиям, после чего результаты агрегируются. Это позволяет учитывать как терминологическую точность, так и смысловую близость. [1], [2], [3], [4]

4.2. Ранжирование

Для повышения качества поиска используется reranking (повторная ранжировка). На этапе ранжирования наиболее вероятно релевантные документы оцениваются более точной моделью. Это особенно важно, когда необходимо выбрать несколько наилучших фрагментов из большого числа кандидатов. [1], [2], [3], [4]

4.3. Генерация ответов

Генерация ответа осуществляется на основе заданного контекста и заранее определенного шаблона. Модель должна ограничиваться извлеченной информацией и не вводить новые сведения без подтверждения. Такой режим уменьшает риск галлюцинаций и делает ответы более предсказуемыми. [1], [2], [3], [4]

4.4. Верификация

Верификация включает несколько уровней проверки: соответствие ответа источникам, контроль структуры, выявление противоречий и проверку диапазонов значений. В случае несоответствия ответ может быть отклонен или отправлен на повторную обработку. [1], [2], [3], [4]

4.5. Обработка ошибок

При ошибках система должна сохранять работоспособность. Возможны следующие действия: возврат к поисковому режиму, уведомление пользователя о недостатке данных, логирование проблемы и исключение недостоверного ответа из выдачи. [1], [2], [3], [4]

---

5. ВЕКТОРИЗАЦИЯ ДАННЫХ В RAG-СИСТЕМАХ

5.1. Понятие векторных представлений

Векторизация текста является основой семантического поиска в RAG-системах. Документы и запросы преобразуются в числовые векторы фиксированной размерности, которые отражают смысловое содержание текста. Чем ближе векторы друг к другу, тем выше семантическая близость соответствующих фрагментов. [1], [2], [3], [4]

5.2. Модели для векторизации текста

Для получения embeddings применяются трансформерные модели, такие как BERT, Sentence-BERT и специализированные embedding-модели. Выбор модели зависит от требований к качеству поиска, вычислительным ресурсам и возможности локального развертывания. [1], [2], [3], [4]

5.3. Процесс векторизации документов и запросов

Процесс включает очистку текста, деление на фрагменты, преобразование каждого фрагмента в вектор и сохранение результатов в векторном хранилище. Для корректной работы системы важно, чтобы документы и запросы преобразовывались одной и той же моделью, иначе сравнение будет некорректным. [1], [2], [3], [4]

5.4. Метрики сходства

Для сопоставления векторов используются cosine similarity, dot product и евклидово расстояние. На практике cosine similarity часто оказывается наиболее удобной, поскольку хорошо отражает семантическую близость и не зависит от длины вектора. [1], [2], [3], [4]

5.5. Векторные базы данных

Векторные базы данных предназначены для хранения embeddings и быстрого поиска ближайших соседей. В зависимости от требований могут применяться FAISS, Milvus, Pinecone и другие решения. Для локальных и критичных сценариев преимущество часто имеют системы, допускающие размещение в защищенном контуре. [1], [2], [3], [4]

5.6. Индексация и ускорение поиска

Для ускорения поиска можно использовать:

Approximate Nearest Neighbors (ANN) – методы, которые быстро находят ближайшие объекты в больших векторных пространствах с небольшим допущением ошибки вместо точного поиска. [1], [2], [3], [4]

HNSW (Hierarchical Navigable Small World) – строит многослойный граф для эффективного поиска соседей через навигацию по «малому миру».

IVF (Inverted File / Inverted Index) – разбивает пространство на кластеры и ищет соседей только внутри ближайших кластеров для ускорения поиска.

Product Quantization (PQ) – сжимает векторы на подпространства с помощью квантования, позволяя быстро сравнивать и искать похожие объекты в памяти.

Эти методы позволяют значительно уменьшить время извлечение без существенной потери качества.

5.7. Влияние качества векторизации на RAG

Качество embeddings напрямую влияет на качество извлечение, а следовательно, и на итоговый ответ. Ошибки в векторизации приводят к извлечению нерелевантных фрагментов, что повышает риск неверной генерации. [1], [2], [3], [4]

5.8. Ограничения и проблемы векторизации

Основными ограничениями являются зависимость от доменной специфики, чувствительность к chunking (структурное разбиение документов), значительные вычислительные затраты и ограниченная интерпретируемость. Для их снижения используется доменная адаптация, гибридный поиск и контроль качества текстовой подготовки. [1], [2], [3], [4]

6. МЕТОДЫ ОБРАБОТКИ ТЕКСТА ДЛЯ УЛУЧШЕНИЯ ПОИСКА

6.1. Роль предобработки текста в RAG-системах

Предобработка текста определяет качество входных данных для всех последующих этапов. В условиях критичной предметной области необходимо минимизировать шум, сохранить структуру документа и обеспечить корректное представление терминов. [1], [2], [3], [4]

6.2. Очистка и нормализация текстовых данных

На данном этапе удаляются служебные символы, исправляются ошибки извлечения текста, нормализуется регистр и устраняются дубликаты. Дополнительно может использоваться лемматизация и приведение терминов к единому виду. [1], [2], [3]

6.3. Структурное разбиение документов (chunking)

Для регламентных документов наиболее эффективным является структурный chunking, при котором текст разбивается по разделам, пунктам и подпунктам. Такой подход позволяет сохранить смысловую целостность и обеспечить точную ссылку на источник. [1], [2], [3]

6.4. Обогащение данных метаданными

Каждый фрагмент может быть дополнен метаданными: типом документа, датой, номером версии, уровнем критичности и источником. Это повышает точность фильтрации и позволяет учитывать актуальность информации. [1], [2], [3]

6.5. Нормализация доменной лексики

Специализированная терминология АЭС требует отдельной обработки. Синонимы, сокращения и варианты обозначения оборудования должны быть

сведены к единому стандарту. Это уменьшает вероятность пропуска релевантных фрагментов. [1], [2], [3]

6.6. Семантическое представление и гибридный поиск

После обработки текста документы могут быть представлены одновременно в лексическом и векторном виде. Гибридный поиск сочетает преимущества точного и семантического сопоставления, что особенно важно для технических и регламентных материалов. [1], [2], [3]

6.7. Reranking результатов поиска

После первичного извлечение применяются методы reranking, позволяющие более точно определить релевантность найденных фрагментов. Это улучшает качество контекста и снижает риск передачи в генеративную модель нерелевантной информации. [1], [2], [3]

6.8. Оптимизация контекста для генерации

Перед генерацией контекст следует очистить от дубликатов, сгруппировать по смыслу и ограничить по объему. Это уменьшает нагрузку на модель и помогает формировать более точный ответ. [1], [2], [3]

---

7. МЕТРИКИ И ОЦЕНКА ЭФФЕКТИВНОСТИ

7.1. Метрики поиска

Для оценки извлечение используются Precision@K и Recall@K. Precision@K показывает долю релевантных документов среди первых K результатов,

$$\text{Precision@K} = \frac{1}{K}\sum_{i=1}^{K} \text{rel}(i)$$

где:

- $\mathrm{rel}(i) = 1$, если элемент на позиции i релевантен,

иначе 0,

а Recall@K – долю найденных релевантных документов от общего их числа. В критичной системе важен баланс между этими метриками: слишком высокая полнота без точности приводит к шуму, а высокая точность без полноты – к пропуску важной информации.

$$\mathrm{Recall@K} = \frac{\sum_{i=1}^{K} \mathrm{rel}(i)}{|\mathscr{R}|}$$

где:

- $\mathrm{rel}(i) \in \{0,1\}$ – релевантность элемента на позиции i
- $\mathscr{R}$ – множество всех релевантных элементов

[1], [2], [5], [6], [7]

7.2. Метрики генерации

К метрикам генерации относятся:

- ROUGE – метрика, измеряющая степень совпадения автоматически сгенерированного текста с эталонным по совпадающим n-граммам, словам или последовательностям.
- F1-score – гармоническое среднее точности (precision) и полноты (recall), отражающее баланс между правильными и пропущенными предсказаниями.

- Faithfulness – показатель того, насколько сгенерированный текст корректно отражает факты, содержащиеся в исходных данных.
- Citation accuracy – мера того, насколько правильно сгенерированный текст цитирует источники или документы, на которые ссылается.

Они позволяют оценить степень совпадения ответа с эталоном, сбалансированность точности и полноты, а также соответствие утверждений источникам. [1], [2], [5], [6], [7]

7.3. Метрики надежности

К надежности относятся

- Hallucination rate – доля сгенерированных моделью утверждений, которые не подтверждаются исходными данными или фактами.
- Unverified statement rate – доля утверждений, для которых модель не смогла предоставить проверяемое подтверждение источником.
- Доля ответов, прошедших верификацию без замечаний – процент ответов, полностью соответствующих проверяемым фактам и не содержащих ошибок при проверке.

Эти показатели особенно важны для систем, работающих с критичными данными. [1], [2], [5], [6], [7]

7.4. Операционные метрики

К операционным метрикам относятся время ответа, устойчивость к нагрузке, стабильность работы и воспроизводимость результата. Для практического применения важно, чтобы система не только выдавала качественный ответ, но и делала это в приемлемое время. [1], [2], [5], [6], [7]

8. БЕЗОПАСНОСТЬ И ОГРАНИЧЕНИЯ

8.1. Ограничения языковых моделей

Языковые модели обладают недетерминированностью и чувствительностью к формулировке запроса. Даже при одинаковом вопросе возможны различающиеся ответы. В критичных системах это ограничивает их применение без дополнительных средств контроля. [1], [2], [5], [6], [7]

8.2. Риски применения

Основные риски включают генерацию некорректных инструкций, пропуск критических действий и появление противоречивых рекомендаций. Для атомной энергетики такие ошибки недопустимы. [1], [2], [5], [6], [7]

8.3. Методы снижения рисков

Для снижения рисков применяются участие человека в принятии решений, ограничение генерации, использование доверенных источников, обязательная верификация и журналирование действий. Такой подход делает систему более предсказуемой и безопасной. [1], [2], [5], [6], [7]

9. ИСПОЛЬЗОВАНИЕ ЛОКАЛЬНЫХ ЯЗЫКОВЫХ МОДЕЛЕЙ В КРИТИЧНЫХ СИСТЕМАХ

9.1. Актуальность применения локальных моделей

Использование локальных языковых моделей особенно важно там, где требуется защитить данные, исключить зависимость от внешней инфраструктуры и обеспечить контроль над вычислительным процессом. Для АЭС это имеет принципиальное значение. [1], [2], [5], [6], [7]

9.2. Требования к локальным моделям

К локальным моделям предъявляются требования надежности, детерминированности, производительности, интегрируемости и аудируемости. Они должны работать стабильно, поддерживать API и обеспечивать трассируемость всех операций. [1], [2], [5], [6], [7]

9.3. Архитектура использования локальных моделей

Локальная модель должна входить в состав RAG-конвейера как компонент генерации, а не как самостоятельный источник знаний. Ее задача – синтезировать ответ на основе извлеченного контекста, подготовленного поисковым модулем. [1], [2], [5], [6], [7]

9.4. Выбор моделей и оптимизация

При выборе модели учитываются размер, качество генерации и требования к ресурсам. Для оптимизации могут использоваться:

- Квантование (Quantization) – уменьшение размера и точности весов модели для ускорения работы и экономии памяти при минимальной потере качества.
- Distillation (Дистилляция) – перенос знаний большой модели в меньшую, обучая её повторять поведение исходной модели.
- Fine-tuning (Тонкая настройка) – дополнительное обучение модели на специфических данных для улучшения её качества на конкретной задаче.
- Instruction tuning (Настройка на инструкции) – обучение модели следовать инструкциям и выполнять задачи по текстовым запросам с улучшением понимания команд.

9.5. Управление качеством генерации

Для повышения качества генерации используются ограничение длины ответа, шаблоны, снижение температуры и обязательное указание источников. Это позволяет уменьшить вариативность и повысить проверяемость результата. [1], [2], [5], [6], [7]

9.6. Верификация при использовании локальных моделей

Даже локальная модель может выдавать недостоверные ответы, поэтому необходимо дополнительное верификационное звено. Оно проверяет соответствие ответа retrieved-контексту, структуре и внутренней логике. [1], [2], [5], [6], [7]

9.7. Ограничения и риски

К ограничениям относятся высокие требования к ресурсам, необходимость поддержки инфраструктуры и возможное снижение качества по сравнению с более крупными облачными моделями. Однако для критичных систем преимущества локального развертывания обычно перевешивают недостатки. [1], [2], [5], [6], [7]

9.8. Архитектурные рекомендации

Рекомендуется использовать локальную модель только в составе RAG-системы, разделять уровни извлечение, генерация и верификация, обеспечивать изоляцию от критичных управляющих контуров и вести полный audit trail (журнал аудита). [1], [2], [5], [6], [7]

ЗАКЛЮЧЕНИЕ

В ходе выполнения задания на практику была рассмотрена проблема разработки архитектуры верифицируемой RAG-системы для поддержки

оператора атомной электростанции. В работе проанализированы существующие подходы к извлечение и генерации, исследованы особенности предметной области, описаны архитектурные компоненты системы, а также методы обработки текста, векторизации и оценки эффективности.

Полученные результаты показывают, что для критичных систем наиболее обоснованным является использование гибридного поиска, структурированной обработки текста, обогащения метаданными, переранжирования и многоуровневой верификации. Такое сочетание позволяет повысить точность, трассируемость и надежность выдаваемых ответов.

Также было установлено, что применение локальных языковых моделей может быть оправдано при условии их включения в контролируемую RAG-архитектуру и строгого ограничения свободы генерации. В целом, разработанная концепция может служить основой для дальнейшего проектирования интеллектуальной системы поддержки принятия решений в критичной отрасли. [1], [2], [5], [6], [7]

СПИСОК ЛИТЕРАТУРЫ

1. Извлечение-Augmented Generation for Knowledge-Intensive NLP Tasks (Lewis P. et al.).
2. Извлечение-Augmented Generation Survey (Gao L. et al.).
3. BM25 and Beyond (Robertson S. Et al.).
4. Attention Is All You Need (Vaswani A. et al.).
5. Assessing the Accuracy and Reliability of Large Language Models in Psychiatry Using Standardized Multiple-Choice Questions: Cross-Sectional Study (Hanss K. et al.)

6. Safety and Security Analysis of Large Language Models: Benchmarking Risk Profile and Harm Potential (Akiri C. et al.)

7. Larger and more instructable language models become less reliable (Zhou et al.)